MACS 203b - Corrections

Bruno Costacèque

29 novembre 2022

Exercice 1

(0) Pour ce premier exercice sur la méthode d'estimation par maximum de vraisemblance, on donne de façon détaillée les étapes à suivre. Le problème abordé dans cet exercice étant un peu inhabituel à cause de la translation a, on donne d'abord un exemple plus simple et qui correspond à un grand nombre de cas rencontrés en général. On suppose **dans cette question seulement** que les X_i sont i.i.d. de même loi exponentielle $\mathcal{E}(\lambda)$. On cherche à estimer λ à partir de nos n observations X_i.

- **Première étape** : expliciter la vraisemblance associée aux données observées $(X_1, \dots, X_n)$ (qui sont supposées connues et restent fixées dans tout l'exercice). On la note L comme *likelihood* et c'est par définition la fonction de densité $f_{(X_1,\dots,X_n)}$ associée à la loi jointe des données, ici supposées être indépendantes et distribuées selon la même loi donnée par l'énoncé. L est prise comme une fonction non seulement des données mais aussi des paramètres qui nous intéressent, souvent notées θ. Il s'agit donc ici d'une fonction de $n+1$ variables, la première étant le paramètre λ de la loi commune à chacun des X_i, de densité $f_{X_i} = f \ \forall i \in [\![1, n]\!]$:

$$\begin{aligned}\forall(\lambda, x_1, \dots, x_n) \in \mathbb{R}_+^* \times \mathbb{R}^n,\ L(\lambda, x_1, \dots, x_n) &= f_{(X_1,\dots,X_n)}(x_1, \dots, x_n) \\ &= \prod_{i=1}^{n} f_{X_i}(x_i) \\ &= \prod_{i=1}^{n} \lambda e^{-\lambda x_i} \\ &= \lambda^n e^{-\lambda \sum_{i=1}^{n} x_i}\end{aligned}$$

- **Deuxième étape** : En déduire la log-vraisemblance $\ell := \log L$, plus simple à maximiser et dont les extrema sont les mêmes que ceux de L par croissance de log. Ici on a :

$$\forall(\lambda, x_1, \dots, x_n) \in \mathbb{R}_+^* \times \mathbb{R}^n,\ \ell(\lambda, X_1, \dots, X_n) = n \log \lambda - \lambda \sum_{i=1}^{n} x_i.$$

- **Troisième étape** : chercher les points critiques de la vraisemblance par rapport aux paramètres qui nous intéressent, ici λ. On doit donc trouver les λ qui annulent la dérivée de la fonction $\lambda \mapsto \ell(\lambda, X_1, \dots, X_n)$. Remarquons que les n dernières variables sont maintenant fixées et sont les données observées $X_1, \dots, X_n$. Notre but est de trouver le paramètre λ le plus "vraisemblable" compte tenu des observations qu'on a, ce qui explique que les n dernières variables sont justement les données disponibles et restent fixes. La dérivée vaut :

$$\partial_1 \ell(\lambda, X_1, \dots, X_n) = \frac{n}{\lambda} - \sum_{i=1}^{n} X_i = n\Big(\frac{1}{\lambda} - \overline{X}_n\Big).$$

Remarque : autant que possible, n'hésitez pas à essayer de faire apparaître des moyennes empiriques quand vous utilisez la méthode du maximum de vraisemblance : cela simplifie beaucoup d'expressions en cachant les signes somme, et il n'est pas rare que l'estimateur recherché s'exprime comme fonction de moyennes empiriques. Vous gagnez donc du temps à faire ce petit jeu d'écriture dès le début.

Ici il n'y a qu'un seul point critique : $\hat{\lambda}_n := (\overline{X}_n)^{-1}$.

- **Quatrième étape** : Vérifier que le point critique obtenu est bien un maximum global. Cette étape est souvent négligée, car elle peut être relativement calculatoire... En effet on doit calculer la dérivée seconde de $\lambda \mapsto \ell(\lambda, X_1, \dots, X_n)$ (ou la Hessienne quand on a plusieurs paramètres) en le point critique, et à vérifier que cette dérivées seconde est négative strictement. Ici :

$$\partial^2_{11} \ell(\lambda, X_1, \dots, X_n) = -\frac{n}{\lambda^2}.$$

Donc en particulier cette dérivée seconde est négative strictement en $\hat{\lambda}_n = (\overline{X}_n)^{-1}$. Le point critique $\hat{\lambda}_n$ est donc bien un maximum local de la log-vraisemblance ℓ. Il s'agit bien d'un maximum global car la fonction $\lambda \mapsto \ell(\lambda, X_1, \dots, X_n)$ est concave.

Conclusion : finalement l'estimateur du maximum de vraisemblance est :

$$\hat{\lambda}_n := (\overline{X}_n)^{-1}.$$

(1) Passons au vrai problème. La vraisemblance est simplement le produit des densités en chaque x_i :

$$\forall (\lambda, a, x_1, \dots, x_n) \in \mathbb{R}_+^* \times \mathbb{R} \times \mathbb{R}^n,\ L(\lambda, a, x_1, \dots, x_n) = \lambda^n e^{-\lambda \sum_{i=1}^n (x_i - a)} \mathbb{1}_{\{\min(x_1, \dots, x_n) \geq a\}}$$

En effet $\mathbb{1}_{\{x_i \geq a\}} \mathbb{1}_{\{x_i \geq a\}} = \mathbb{1}_{\{\min(x_1, \dots, x_n) \geq a\}}$. Cette fois les choses se passent (un peu) moins bien. Non pas à cause du nombre de paramètres (on travaillerait avec des gradients et des Hessiennes au lieu de dérivées premières et secondes), mais parce que la fonction $(\lambda, a) \mapsto L(\lambda, a, X_1, \dots, X_n)$ n'est pas dérivable en a à cause de l'indicatrice (elle n'est même pas continue !). On va donc maximiser par rapport à chaque variable séparément, en fixant l'autre :

- Fixons d'abord $a \geq \min(X_1, \dots, X_n)$. En effet la vraisemblance est strictement positive lorsque l'indicatrice vaut 1. Il est donc clair qu'on ne cherchera l'estimateur de a que dans l'intervalle $]-\infty, \min(X_1, \dots, X_n)]$. Ceci fait, la fonction $\lambda \mapsto L(\lambda, a, X_1, \dots, X_n)$ est alors dérivable sur $\mathbb{R}_+^*$. En appliquant exactement le même raisonnement qu'à la question **(0)**, on trouve cette fois :

$$\hat{\lambda}_n = \frac{1}{\frac{1}{n}\sum_{i=1}^n (X_i - a)}.$$

- Fixons maintenant $\lambda = \hat{\lambda}_n$. On doit trouver $a \in]-\infty, \min(X_1, \dots, X_n)]$ qui maximise $a \mapsto L(\hat{\lambda}_n, a, X_1, \dots, X_n)$. On peut oublier l'indicatrice, qui vaut 1, puisque $a \leq \min(X_1, \dots, X_n)$. Mais $a \mapsto (\hat{\lambda}_n)^n e^{-\hat{\lambda}_n \sum_{i=1}^n (x_i - a)} = (\overline{X}_n - a)^{-n}$ est croissante sur $]-\infty, \min(X_1, \dots, X_n)]$, et donc atteint son maximum en $\hat{a}_n := \min(X_1, \dots, X_n)$.

Conclusion : finalement l'estimateur du maximum de vraisemblance est :

$$(\hat{\lambda}_n, \hat{a}_n) := \Big(\frac{1}{\overline{X}_n - \min(X_1, \dots, X_n)}, \min(X_1, \dots, X_n) \Big).$$

(2) Le terme problématique est $\hat{a}_n$, puisque si on prouve sa convergence vers a, on aura la convergence de $(\hat{\lambda}_n)_n$ par la loi forte des grands nombres et par continuité de la fonction $x \mapsto x^{-1}$ sur $\mathbb{R}_+^*$. On va utiliser le second lemme de Borel-Cantelli pour cela (l'alternative vue en cours est brièvement rappelée à la fin de la preuve). L'idée est simple : on a affaire à une suite infinie de variables aléatoires $(X_n)_n$ i.i.d. (définies sur le même espace de probabilité) dont le support est minoré par un paramètre a. Intuitivement, on s'attend à ce que sur cette infinité de variables aléatoires certaines prennent des valeurs arbitrairement proches de a, et ce infiniment souvent. On aura alors par définition de l'infimum d'une suite réelle :

$$\inf_{n \in \mathbb{N}^*} X_n = \lim_{n \to \infty} \min(X_1, \dots, X_n) = a.$$

Posons $A_i := \{X_i < a + \varepsilon\}$. Ces événements sont **indépendants** car les X_i le sont. De plus ils ont tous même probabilité strictement positive $e^{-\lambda\varepsilon}$. On en déduit que :

$$\sum_{i=1}^{\infty} \mathbb{P}(A_i) = \infty.$$

Aussi, pour chaque ε, il existe presque sûrement une infinité de X_i prenant des valeurs inférieures à $a + \varepsilon$. Comme $X_i \geq a$ presque sûrement, on en déduit que l'événement $(a \leq X_i \leq a + \varepsilon)$ est réalisé une infinité de fois presque sûrement. Cela suffit pour prouver que $\inf_{n \in \mathbb{N}^*} X_n = a$ presque sûrement. Par ailleurs, comme $\mathbb{E}[X_1] = \lambda^{-1} + a$, puisque $X_1 - a$ suit la loi exponentielle $\mathcal{E}\lambda$, la loi forte des grands nombres donne que $\overline{X}_n$ converge vers $\lambda^{-1} + a$. Ainsi on a bien obtenu que :

$$\lim_{n \to \infty} (\hat{\lambda}_n, \hat{a}_n) = (\lambda, a) \text{ p.s.},$$

puisque l'intersection de deux événements presque sûrs reste un évènement presque sûr [1].

Alternative : On peut aussi calculer $\mathbb{P}(|\hat{a}_n - a| > \varepsilon) = \mathbb{P}(\hat{a}_n - a > \varepsilon)$. Cette quantité est le terme général d'une série convergente. Un résultat du cours assure alors la convergence presque sûre de $\hat{a}_n$ vers a.

Exercice 3

(1) Par définition $\limsup_n A_n = \bigcap_{n=1}^{\infty} \bigcup_{k=n}^{\infty} A_k$. Or la suite d'événements $\big(\bigcup_{k=n}^{\infty} A_k\big)_n$ est **décroissante** pour l'inclusion. Par théorème de continuité monotone, on a donc :

$$\mathbb{P}(\limsup_n A_n) = \lim_{n \to \infty} \mathbb{P}\Big(\bigcup_{k \geq n} A_k \Big).$$

1. Dit autrement, les convergence de $\overline{X}_n$ et de $\hat{a}_n$ ont lieu sur deux évènements de probabilité 1 : ces termes convergent donc simultanément sur l'intersection de ces deux événements, qui est encore de probabilité 1.

On cherche à utiliser l'hypothèse d'indépendance des A_k pour se débarrasser de cette réunion. Pour cela on passe au complémentaire et on utilise les règles de de Morgan :

$$\begin{aligned}\mathbb{P}\Big(\bigcup_{k\geq n} A_k\Big) &= 1 - \mathbb{P}\Big(\bigcap_{k\geq n} A_k^c\Big) \\ &= 1 - \prod_{k\geq n} \mathbb{P}(A_k^c) \\ &= 1 - \prod_{k\geq n} \Big(1 - \mathbb{P}(A_k)\Big). \end{aligned} \tag{1}$$

Prouvons que ce produit infini est en fait nul grâce à l'hypothèse de divergence de l'énoncé. L'inégalité de convexité classique $1 + x \leq e^x$ valable pour tout réel x donne :

$$\prod_{k\geq n} \Big(1 - \mathbb{P}(A_k)\Big) \leq \prod_{k\geq n} e^{-\mathbb{P}(A_k)} = e^{-\sum_{k\geq n} \mathbb{P}(A_k)} = 0,$$

puisque le reste d'une série divergente est aussi divergent. En faisant tendre n vers l'infini dans (1), on trouve le résultat.

(2) Il suffit d'appliquer le second lemme de Borel-Cantelli aux événements $A_n := \{X_n = 1\}$, qui sont bien **indépendants** par indépendance des X_n. De plus la série $\sum_n \mathbb{P}(A_n)$ est bien divergente puisque $\forall n \in \mathbb{N},\ \mathbb{P}(A_n) = p > 0$. On fait la même chose pour la seconde partie de la question en prenant cette fois $A_n := \{X_n = -1\}$. Ces événements sont bien indépendants, et la série associée diverge car $\forall n \in \mathbb{N},\ \mathbb{P}(A_n) = 1 - p > 0$ puisque $p > 1$.

(3) Ce qui suit est vrai car la marche aléatoire $(S_n)_n$ démarre en 0, *i.e.* $S_0 = 0$. Si elle avait démarré en un nombre impair par exemple, ce serait $\{S_{2n} = 0\}$ qui serait de probabilité nulle par exemple !

- Remarquons que S_{2n+1} est toujours impaire. L'événement $\{S_{2n+1} = 0\}$ est donc de probabilité nulle :

$$\forall n \in \mathbb{N},\ \mathbb{P}(S_{2n+1} = 0) = 0.$$

- Puisque l'on part de 0 au temps $n = 0$, on ne peut y revenir que si l'on fait autant de pas en avant ($X_k = 1$) qu'en arrière ($X_k = -1$) au cours des $2n$ unités de temps qui s'écoule entre l'instant initial et le retour en 0 à l'instant $2n$. Puisque ne pas avancer signifie reculer [2], cela signifie encore qu'on doit effectuer n pas en avant au cours des $2n$ unités de temps, le reste étant forcément des pas en arrière. Pour formaliser cela, notons B_n la variable aléatoire qui compte le nombre de pas en avant effectués par la marche avant l'instant n. Les événements $\{X_k = 1\}$ étant de même probabilité (égales à p) et indépendants, il est clair que B_n suit la loi binomial $\mathcal{B}(n, p)$. On a alors que $\{S_{2n} = 0\} = \{B_{2n} = n\}$ et donc :

$$\mathbb{P}(S_{2n} = 0) = \mathbb{P}(B_{2n} = n) = \binom{2n}{n} p^n (1-p)^n.$$

2. *i.e.* $\{X_k = 1\}^c = \{X_k = -1\}$.

(4) On propose deux méthodes : une dans l'esprit de l'exercice et assez générale, l'autre plus spécifique mais aussi plus rapide.

- La formulation de la question invite à utiliser le **premier** lemme de Borel-Cantelli (vu en cours). En effet le but est de prouver que, presque sûrement, un certain événement ne se produit qu'un nombre fini de fois. On est naturellement amené à prendre $A_n := \{S_n = 0\}$. Comme ces événements ne sont **pas** indépendants, il est hors de question de leur appliquer le second lemme de Borel-Cantelli [3]. Prouvons donc que la série $\sum_n \mathbb{P}(A_n)$ est convergente, ou plutôt $\sum_n \mathbb{P}(A_{2n})$, puisque les termes d'indice impair sont de probabilité nulle par la question précédente. La formule de Stirling donne :

$$\mathbb{P}(A_{2n}) = \mathbb{P}(S_{2n} = 0) = \underset{n\to\infty}{\sim} \frac{4^n}{\sqrt{\pi n}} p^n (1-p)^n.$$

  Mais la fonction $x \mapsto x(1-x)$ atteint son maximum égal à $1/4$ en $x = 1/2$ sur $[0,1]$. Comme $p \neq 1/2$, on a donc $p(1-p) = \alpha/4$, avec $\alpha \in]0,1[$. Aussi :

$$\mathbb{P}(A_{2n}) = \underset{n\to\infty}{\sim} \frac{\alpha^n}{\sqrt{\pi n}}.$$

  Il s'agit du terme général d'une série convergente, ce qui conclut la preuve.

- On peut aussi utiliser la loi forte des grands nombres. Puisque $\mathbb{E}[X_1] = 2p-1$, on a que :

$$\frac{1}{n}\sum_{k=1}^{n} X_k = \frac{S_n}{n} \underset{n\to\infty}{\to} 2p-1 \text{ p.s.}$$

  Cette dernière quantité est différente de 0 quand $p \neq 1/2$, donc $S_n \underset{n\to\infty}{\sim} (2p-1)n$ presque sûrement. En particulier $(S_n)_n$ diverge vers plus ou moins l'infini, selon le signe de $2p-1$, et ne peut donc revenir en 0 qu'un nombre fini de fois presque sûrement.

Exercice 4

(1) Pour $\varepsilon > -1$, un calcul élémentaire donne :

$$\mathbb{P}\Big(\frac{X_n}{\log n} \geq 1+\varepsilon\Big) = \frac{1}{n^{1+\varepsilon}}.$$

(2) Si $\varepsilon > 0$, la série de terme général $\mathbb{P}(X_n/\log n \geq 1+\varepsilon)$ converge. On peut donc utiliser le premier lemme de Borel-Cantelli. Elle diverge quand ε est négatif (ou nul). Les variables X_n sont indépendantes donc le second lemme de Borel s'applique dans ce second.

(3) Posons $Y := \limsup_{n\to\infty} \log n \geq 1+\varepsilon$. Il s'agit d'une variable aléatoire (pourquoi ?), à valeurs dans $[0,+\infty]$. Nous allons étudier sa fonction de queue $\overline{F}_Y := 1 - F_Y$. Remarquons les inclusions suivantes, valables pour $a \geq 0$ et $\varepsilon > 0$:

$$\limsup_n \Big\{\frac{X_n}{\log n} \geq a+\varepsilon\Big\} \subseteq \{Y > a\} \subseteq \limsup_n \Big\{\frac{X_n}{\log n} > a\Big\}.$$

3. Il existe des versions de ce lemme pour lesquelles l'hypothèse d'indépendance est affaiblie.

Les inégalités larges ou strictes sont très importantes ici, puisque la fonction de répartition de la loi de Y est celle d'une Dirac en 1 (c'est ce que doit prouver en tout cas). Elle n'est donc pas continue à gauche. La première inclusion se justifie en disant que si $X_n/\log n$ est supérieur à $a+\varepsilon$ une infinité de fois, alors sa plus grande valeur d'adhérence est supérieure **ou égale** à $a+\varepsilon$, donc strictement supérieure à a. La seconde inclusion dit simplement que si la plus grande valeur d'adhérence de $(X_n/\log n)_n$ est strictement plus grande que a, alors on peut trouver une sous-suite $(X_{\varphi(n)}/\log(\varphi(n)))_n$ dont tous les termes sont eux-mêmes strictement plus grands que a (raisonnez par contraposée). En particulier une infinité de termes de $(X_n/\log n)_n$ sont plus grands que a strictement.

En utilisant la question précédente, on trouve alors :

$$\overline{F}_Y(a) = \begin{cases} 0 & \text{si } a > 1 \\ 1 & \text{si } a \leq 1. \end{cases}$$

En effet, si $a > 1$, disons $a = 1+\delta$ avec $\delta > 0$, alors le membre de gauche de la double inclusion précédente donne :

$$\overline{F}_Y(a) = \mathbb{P}(Y > a) \leq \mathbb{P}\Big(\limsup_n \Big(\frac{X_n}{\log n} > 1+\delta \Big) \Big) = 0$$

.

Et si $a < 1$, disons $a = 1-\delta$, avec $\delta > 0$, alors on prend dans l'inclusion de gauche précédente $a = 1-\delta$ et $\varepsilon = \delta/2$. on obtient alors :

$$\overline{F}_Y(a) = \mathbb{P}(Y > a) \geq \mathbb{P}\Big(\limsup_n \Big(\frac{X_n}{\log n} > 1-\frac{\delta}{2} \Big) \Big) = 1$$

.

Enfin si $a = 1$, on conclut simplement par continuité **à droite** de $\overline{F}_Y$. Finalement on a trouvé que F_Y est la fonction de répartition d'une loi de Dirac en 1. Donc $Y = 1$ presque sûrement.

MACS 203b - Corrections

Bruno Costacèque

4 janvier 2023

Exercice 5

(1) C'est une simple réécriture de la définition :

$$\begin{aligned}\{N(t) < n\} &= \Big\{ \max\{m \in \mathbb{N}^* \mid T_m \leq t\} < n \Big\} \\ &= \Big\{ n \notin \{m \in \mathbb{N}^* \mid T_m \leq t \Big\} \\ &= \{T_n > t\}.\end{aligned}$$

(2) Par ce qui précède :

$$\mathbb{P}(N(t) < n) = \mathbb{P}(T_n > t).$$

Puisque T_n est à valeurs positives et intégrable, l'inégalité de Markov donne :

$$\mathbb{P}(T_n > t) \leq \frac{\mathbb{E}[T_n]}{t}.$$

On en déduit le résultat attendu en faisant tendre t vers l'infini par théorème d'encadrement.

(3) Remarquons d'abord que la fonction $N : t \mapsto N(t)$ est croissante presque sûrement. Elle admet donc une limite $N(\infty) \in [0, \infty]$ presque sûrement. Supposons que cette limite soit finie presque sûrement. Par convergence dominée $\lim_{t\to\infty} \mathbb{P}(N(t) < n) = \mathbb{P}(N(\infty) \leq n)$ quelque soit $n \in \mathbb{N}^*$. Par la question précédente que :

$$\forall n \in \mathbb{N}^*,\ \mathbb{P}(N(\infty) \leq n) = \lim_{t\to\infty} \mathbb{P}(N(t) < n) = 0.$$

Comme $\mathbb{P}(N(\infty) < \infty) = \sum_{n\in\mathbb{N}} \mathbb{P}(N(\infty) = n)$, on en déduit que $\mathbb{P}(N(\infty) < \infty) = 0$ et donc que $N(\infty) = \lim_{t\to\infty} N(t) = \infty$ presque sûrement.

(4)

- L'inégalité de gauche est une conséquence de la définition de $N(t)$ qui assure $T_{N(t)} \leq t$, puisque le maximum est atteint (on sait que T_n tend vers l'infini [1] quand n tend vers l'infini p.s.).

1. Car les X_i sont i.i.d. et supposées positives p.s., d'espérances strictement positives.

- Pour ce qui est de l'inégalité de droite, c'est encore une conséquence de la définition de $N(t)$. Remarquons d'abord que le membre de droite s'écrit :

$$\frac{T_{N(t)+1}}{N(t)+1}\Big(1+\frac{1}{N(t)}\Big) = \frac{T_{N(t)+1}}{N(t)}.$$

  Mais par définition de $N(t)$, on a que $N(t)+1 \notin \{m \in \mathbb{N}^* \mid T_m \leq t\}$, et donc nécessairement $t < T_{N(t)+1}$. Cela conclut.

(5) Puisque $N(t)$ tend vers l'infini presque sûrement quand t tend vers l'infini par la question 4, la loi forte des grands nombres s'applique aux deux membres de gauche et de droite de l'inégalité de la question précédente. Ceux-ci tendent vers $\mathbb{E}[X_1]$ presque sûrement. On en déduit que $\frac{N(t)}{t}$ tend vers $\mathbb{E}[X_1]$ presque sûrement.

Exercice 7

(1) Soit $x \in \mathbb{R}$. Trouver la fonction de répartition de $\hat{\theta}_n$, c'est calculer la probabilité de l'événement $\{\hat{\theta}_n \leq x\}$. On utilise l'astuce classique concernant les suprema de variables aléatoires indépendantes : l'événement $\{\hat{\theta}_n \leq x\}$ s'écrit encore :

$$\begin{aligned}\{\hat{\theta}_n \leq x\} &= \{\max(X_1,\dots,X_n) \leq x\} \\ &= \bigcap_{i=1}^{n} \{X_i \leq x\}\end{aligned}$$

Par indépendance des X_i, on a donc :

$$\begin{aligned}F_{\hat{\theta}_n}(x) &= \mathbb{P}\Big(\bigcap_{i=1}^{n}\{X_i \leq x\}\Big) \\ &= \prod_{i=1}^{n} \mathbb{P}(X_i \leq x) \\ &= \prod_{i=1}^{n} F_{X_i}(x) \\ &= (F_{X_1}(x))^n.\end{aligned}$$

La dernière égalité est justifiée par le fait que tous les X_i suivent la même loi. On en déduit :

$$F_{\hat{\theta}_n}(x) = \begin{cases} 0 & \text{si } x \leq 0 \\ \left(\frac{x}{\theta}\right)^n & \text{si } x \in [0,\theta] \\ 1 & \text{si } x \geq \theta. \end{cases}$$

(2) Puisque $n \geq 0$, on a :

$$\begin{aligned} F_{n(\theta-\hat{\theta}_n)}(x) &= \mathbb{P}(n(\theta-\hat{\theta}_n) \leq x) \\ &= \mathbb{P}\Big(\theta - \hat{\theta}_n \leq \frac{x}{n}\Big) \\ &= \mathbb{P}\Big(\hat{\theta}_n \geq \theta - \frac{x}{n}\Big) \\ &= 1 - F_{\hat{\theta}_n}\Big(\theta - \frac{x}{n}\Big) \end{aligned}$$

D'où finalement :

$$F_{n(\theta-\hat{\theta}_n)}(x) = \begin{cases} 0 & \text{si } x \leq 0 \\ 1 - \Big(1 - \frac{x}{n\theta}\Big)^n & \text{si } x \in [0, n\theta] \\ 1 & \text{si } x \geq n\theta. \end{cases}$$

(3) On calcule la limite de $F_{n(\theta-\hat{\theta}_n)}$ en chaque point de continuité de cette fonction. On trouve sans difficultés :

$$\lim_{n\to\infty} F_{n(\theta-\hat{\theta}_n)}(x) = \begin{cases} 0 & \text{si } x \leq 0 \\ 1 - e^{-\frac{x}{\theta}} & \text{si } x \in [0, \theta]. \end{cases}$$

Conclusion : la suite de lois de probabilité des $\Delta_n = n(\theta - \hat{\theta}_n)$ converge en loi vers la loi exponentielle de paramètre $1/\theta$, notée aussi $\mathcal{E}(1/\theta)$. En particulier $\hat{\theta}_n$ converge en loi vers θ à vitesse $1/n$. Remarquons aussi que la loi limite des fluctuations de $\hat{\theta}_n$ autour de θ (*i.e.* Δ_n) admet justement comme espérance θ.

(4) Cet estimateur converge presque sûrement vers θ. La vitesse de convergence est donnée par le théorème central limite et vaut $1/\sqrt{n}$. On prouve de la même façon qu'à l'exercice 1 que $\hat{\theta}_n$ converge presque sûrement vers θ lui aussi (et pas juste en loi). Ainsi au vu des modes et des vitesses de convergence de chacun des deux estimateurs, il apparaît que $\hat{\theta}_n$ est le plus "intéressant".

Exercice 8

(1) On prend $U_n \hookrightarrow \mathcal{B}(\frac{1}{n})$ et indépendante de X. Il est alors clair que :

$$\mathbb{E}[X_n] = \mathbb{E}[X]\Big(1 - \frac{1}{n}\Big) + n \times \frac{1}{n} = \mathbb{E}[X]\Big(1 - \frac{1}{n}\Big) + 1.$$

En particulier $\lim_{n\to\infty} \mathbb{E}[X_n] = \mathbb{E}[X] + 1 \neq \mathbb{E}[X]$. Par ailleurs, on a :

$$\begin{aligned} F_{X_n}(x) &= \mathbb{P}(X_n \leq x) \\ &= \frac{1}{n}\mathbb{P}(n \leq x) + \Big(1 - \frac{1}{n}\Big)\mathbb{P}(X \leq x), \end{aligned}$$

en conditionnant par les événements $\{U_n = 1\}$ et $\{U_n = 0\}$. Il est immédiat que $\lim_{n\to\infty} F_{X_n}(x) = F_X(x)$ dès que x est un point de continuité de F_X. Cela prouve la convergence en loi de X_n vers X et fournit le contre-exemple demandé.

(2) Cette question semble être une application directe du lemme de Fatou aux variables **positives** $|X_n|$. Cependant rien n'oblige les variables X_n et X à vivre sur le même espace probabilisé. Mais puisque $(X_n)_n$ converge en loi vers X, le théorème de représentation de Skorokhod nous fournit une variable aléatoire Y de même loi que X et une suite de variables aléatoires $(Y_n)_n$ définies sur le même espace de probabilité que Y, avec $\forall n \in \mathbb{N},\ Y_n \overset{\mathcal{L}}{=} X_n$ et $Y_n \underset{n\to\infty}{\to} X$ presque sûrement. Comme l'espérance ne dépend que de la loi, on en déduit :

$$\mathbb{E}[|X|] = \mathbb{E}[|Y|] = \mathbb{E}[\liminf_n |Y_n|] \leq \liminf_n \mathbb{E}[|Y_n|] = \liminf_n \mathbb{E}[|X_n|],$$

en appliquant le lemme de Fatou à la suite $(Y_n)_n$.

(3) Par hypothèse, il existe $A \in \mathbb{R}_+$ tel que :

$$\forall a \geq A,\ \sup_n \mathbb{E}\Big[|X_n| \mathbb{1}_{\{|X_n|\geq a\}}\Big] \leq 1.$$

Par ailleurs, on a :

$$\begin{aligned}\forall n \in \mathbb{N},\ \mathbb{E}\Big[|X_n|\Big] &= \mathbb{E}\Big[|X_n| \mathbb{1}_{\{|X_n|\geq A\}}\Big] + \mathbb{E}\Big[|X_n| \mathbb{1}_{\{|X_n|\leq A\}}\Big] \\ &\leq 1 + A\mathbb{P}(|X_n| \leq A) \\ &\leq 1 + A.\end{aligned}$$

Ainsi $\sup_n \mathbb{E}[|X_n|] < \infty$.

(4) Rappelons que $\liminf_n \mathbb{E}[|X_n|] = \sup_n \inf_{k\geq n} \mathbb{E}[|X_k|]$. Comme on suppose toujours que $(X_n)_n$ converge en loi vers X, on en déduit par la question **(2)**, puis par la question **(3)** que :

$$\mathbb{E}[|X|] \leq \sup_n \inf_{k\geq n} \mathbb{E}[|X_k|] \leq \sup_n \mathbb{E}[|X_n|] < \infty.$$

(5) Soit $A > 0$. On a :

$$\forall n \in \mathbb{N},\ \mathbb{E}[X_n] = \mathbb{E}\Big[X_n \mathbb{1}_{\{X_n\geq A\}}\Big] + \mathbb{E}\Big[X_n \mathbb{1}_{\{X_n\leq A\}}\Big].$$

Soit $\varepsilon > 0$. Puisque la suite $(X_n)_n$ est uniformément intégrable, on peut trouver A tel que $\forall n,\ \mathbb{E}\Big[X_n \mathbb{1}_{\{X_n\geq A\}}\Big] \leq \varepsilon$. Concernant le second terme, on peut supposer que X_n converge presque sûrement vers X quitte à changer de variables aléatoires (comprendre : quitte à utiliser le théorème de Skorohod). Le terme $X_n \mathbb{1}_{\{X_n\leq A\}}$ est dominé par A et converge presque sûrement vers $X\mathbb{1}_{\{X\leq A\}}$, **dès que A est un point de continuité de** F_X. En effet, la fonction $x \mapsto \mathbb{1}_{\{x\leq A\}}$ est continue partout sauf en A. Mais $\mathbb{P}(X = A) = 0$ puisque A est un point de continuité de F_X (et donc $\mathbb{P}(X \leq A) = \mathbb{P}(X < A)$, d'où $\mathbb{P}(X = A) = \mathbb{P}(X \leq A) - \mathbb{P}(X < A) = 0$). Ceci pour dire que $\{X = a\}$ est négligeable et donc que $x \mapsto \mathbb{1}_{\{x\leq A\}}$ est continue $\mathbb{P}_X-$presque partout. Enfin on remarque :

$$\mathbb{E}\Big[X\mathbb{1}_{\{X\leq A\}}\Big] = \mathbb{E}[X] + \varepsilon,$$

en supposant A assez grand pour que $\mathbb{E}\Big[X\mathbb{1}_{\{X\geq A\}}\Big]$ soit inférieur ou égal à ε (ce qui est possible car X est intégrable, par la question précédente). Finalement :

$$\lim_{n\to\infty}\mathbb{E}[X_n]\leq\mathbb{E}[X]+2\varepsilon,$$

En remplaçant $(X_n)_n$ par $(-X_n)_n$ et X par $-X$ (toutes les hypothèses sont encore trivialement vérifiées !), on trouve :

$$\lim_{n\to\infty}\mathbb{E}[X_n]\geq\mathbb{E}[X]-2\varepsilon,$$

Cela conclut.

(6) Nous allons prouver un résultat plus général :

Proposition 1. *Une suite de variables aléatoires $(X_n)_n$ intégrables est uniformément intégrable s'il existe une fonction φ à valeurs positives sur $\mathbb{R}_+$ telle que*

$$\lim_{x\to\infty}\frac{\varphi(x)}{x}=+\infty \text{ et}$$

$$\sup_{n\geq 0}\mathbb{E}\Big[\varphi(|X_n|)\Big]<\infty.$$

Démonstration. Puisque $\lim_{x\to\infty}\frac{x}{\varphi(x)}=0$, pour tout $\varepsilon>0$, il existe $A\geq 0$ tel que pour $x\geq A$, on ait $\frac{x}{\varphi(x)}\leq\varepsilon$, et donc $x\leq\varepsilon\varphi(x)$ (puisque φ est à valeurs positives). On en déduit pour tout $n\in\mathbb{N}$:

$$\mathbb{E}\Big[|X_n|\mathbb{1}_{\{|X_n|\geq x\}}\Big]\leq\varepsilon\mathbb{E}\Big[\varphi(|X_n|)\mathbb{1}_{\{|X_n|\geq x\}}\Big]\leq\varepsilon\sup_{n\geq 0}\mathbb{E}\Big[\varphi(|X_n|)\Big].$$

Ce dernier supremum étant fini et ε étant arbitraire, on en déduit le proposition.

□

On applique alors ce résultat à la fonction $x\mapsto|x|^{1+\varepsilon}$. Un autre exemple d'application intéressant est la fonction $x\mapsto x(\log x)_+$.

Remarque 1. *On peut prouver un résultat encore plus fort :*

Théorème 2 (De la Vallée Pousin)**.** *Une suite de variables aléatoires $(X_n)_n$ intégrables est uniformément intégrable* ***si et seulement si*** *existe une fonction φ à valeurs positives sur $\mathbb{R}_+$,* ***convexe*** *et* ***croissante*** *telle que*

$$\lim_{x\to\infty}\frac{\varphi(x)}{x}=+\infty \text{ et}$$

$$\sup_{n\geq 0}\mathbb{E}\Big[\varphi(|X_n|)\Big]<\infty.$$

Démonstration. Le sens réciproque a déjà été prouvé (sous des hypothèses plus faibles). Prouvons le sens direct. On suppose la suite $(X_n)_n$ uniformément intégrable et on cherche à construire une fonction φ satisfaisant les hypothèses de l'énoncé. Nous allons suivre la preuve très élégante donnée par Nicolas Fournier [2]. Par hypothèse, pour tout $m \geq 1$, on peut trouver $x_m \geq 0$ tel que :

$$\mathbb{E}\Big[|X_n|\mathbb{1}_{\{|X_n|\geq x_m\}}\Big] \leq \frac{1}{2^m}$$

On pose alors :

$$\varphi(x) := \sum_{m=1}^{\infty} (x - x_m)_+$$

Malgré les apparences, cette série est en fait une somme finie [3], et donc est convergente. Elle est en particulier convexe et croissante, comme somme de telles fonctions. De plus, par convergence monotone :

$$\lim_{x\to\infty} \frac{\varphi(x)}{x} = \sum_{m=1}^{\infty} \left(1 - \frac{x_m}{x}\right)_+ \underset{x\to\infty}{\to} +\infty.$$

Enfin on a une nouvelle fois par convergence monotone :

$$\begin{aligned}
\forall n \in \mathbb{N},\ \mathbb{E}\Big[\varphi(|X_n|)\Big] &= \sum_{m=1}^{\infty} \mathbb{E}\Big[(|X_m| - x_m)_+\Big] \\
&= \sum_{m=1}^{\infty} \mathbb{E}\Big[(|X_m| - x_m)\mathbb{1}_{\{|X_m|\geq x_m\}}\Big] \\
&\leq \sum_{m=1}^{\infty} \mathbb{E}\Big[|X_m|\mathbb{1}_{\{|X_m|\geq x_m\}}\Big] \\
&\leq 1.
\end{aligned}$$

□

Le sens direct de ce théorème (uniforme intégrabilité ⇒ existence de φ) peut être très utile dans certains contextes, par exemple pour démontrer des résultats sur les convergences dans $\mathbb{L}^1$ de martingales (voir par exemple le livre de P.Baldi, Stochastic Calculus - An Introduction Through Theory and Exercises).

Exercice 9

(1) L'hypothèse de l'énoncé implique, entre autres, que toute variable aléatoire suivant la loi μ_n est de norme intégrable. Suivons donc l'indice de l'énoncé : on applique l'inégalité de Markov [4] aux variables aléatoires positives (et intégrables) $\|X_n\|$, où X_n est une variable aléatoire de loi μ_n (une telle variable aléatoire existe toujours). On a alors :

2. Voir le lien :
`https://djalil.chafai.net/blog/2014/03/09/de-la-vallee-poussin-on-uniform-integrability/`.

3. Dont le nombre de termes dépend de x !

4. L'inégalité de Markov habituelle s'exprime à l'aide d'une signe "supérieur ou égal" large, alors qu'il nous faut un sens strict pour travailler avec des compacts. On peut mettre sans soucis ce sens strict dans l'inégalité de Markov, la preuve (avec les indicatrices) restant exactement la même que d'habitude.

$$\forall R \in \mathbb{R}_+^*,\ \mathbb{P}(\|X_n\| > R) \leq \frac{\mathbb{E}[\|X_n\|]}{R} \leq \frac{\sup_n \mathbb{E}[\|X_n\|]}{R},$$

et le membre de droite de cette inégalité est fini par hypothèse. Soit $\varepsilon > 0$. On prend $R_\varepsilon := \frac{1}{\varepsilon} \sup_n \mathbb{E}[\|X_n\|]$. L'inégalité précédente implique que le compact $K_\varepsilon := \overline{B}(0, R_\varepsilon)$ vérifie :

$$\forall n \in \mathbb{N}^*,\ \mathbb{P}(\|X_n\| > R_\varepsilon) = \mathbb{P}(X_n \notin K_\varepsilon) = \mu_n(K_\varepsilon^c) \leq \varepsilon.$$

Remarque 3. *Cet argument ne fonctionne* ***jamais*** *en dimension infinie, car dans ce cas (et c'est une équivalence) les boules fermées ne sont pas compactes. Cela pose problème pour prouver ce critère dans le cas des convergences de processus stochastiques, qui sont des variables aléatoires à valeurs dans des espaces fonctionnels, eux-mêmes presque toujours de dimension infinie.*

(2) Remarquons que pour V égale à la fonction norme, on retrouve bien le résultat précédent. Cette question en donne donc bien une généralisation. De plus l'argument est exactement le même qu'à la question précédente, en prenant $K_\varepsilon = \{x \in \mathbb{R}^d\ V(x) \leq R_\varepsilon\} = V^{-1}([0, R_\varepsilon])$, avec $R_\varepsilon = \frac{1}{\varepsilon} \sup_n \mathbb{E}[V(X_n)]$ (prenez le temps de vérifier que vous utilisez bien toutes les hypothèses de l'énoncé : aucune n'est superflue !).

Exercice 10

Rappels : Ils s'imposent si on ne veut pas que l'exercice dégénère rapidement !

- Par définition, $\mathbb{E}[Y|X]$ est une variable aléatoire $\sigma(Y)-$mesurable. Elle s'écrit donc presque sûrement comme composition d'une fonction mesurable et de X :

$$\mathbb{E}[Y|X] = f(X)\ \mathbb{P} - \text{p.s.}$$

  La **notation** standard pour désigner f est $\mathbb{E}[Y|X = x] := f(x)$. Avec cette notation, l'égalité précédente se réécrit :

$$\mathbb{E}[Y|X] = \mathbb{E}[Y|X = x]_{|x=X}\ \mathbb{P} - \text{p.s.}$$

- Soit $(X_n)_n$ une chaîne de Markov sur $(\Omega, \mathcal{F}, (\mathcal{F}_n)_n, \mathbb{P})$ à valeurs dans $(E, \mathcal{E})$ un espace d'états mesurable. Alors par définition elle vérifie :

$$\forall A \in \mathcal{E},\ \forall n \in \mathbb{N},\ \mathbb{P}(X_{n+1} \in A \mid \mathcal{F}_n) = \mathbb{P}(X_{n+1}\ \in A|\ X_n)\ \mathbb{P} - \text{p.s.}$$

- On notera νK la forme linéaire associée au noyau K définie par :

$$\forall h \text{ borélienne bornée},\ \nu K(h) = \int_{\mathbb{R}^d} Kh(x) \mathrm{d}\nu(x) = \mathbb{E}_\nu[Kh(X_0)].$$

  En d'autre termes, $\nu K(h)$ est l'espérance de $h(X_1)$ quand la loi initiale de la chaîne est ν (*i.e.* $\mathcal{L}(X_0) = \nu$. Il s'agit donc d'un réel [5]. Par définition du noyau d'une chaîne de Markov, on en déduit plus généralement que :

5. Contrairement à Kh qui est une fonction, définie par $Kh(x) = \mathbb{E}[h(X_1)|X_0 = x]$.

$$\forall h \text{ borélienne bornée, } \forall n \in \mathbb{N},\ \nu K^n(h) = \mathbb{E}_\nu[K^n h(X_0)].$$

(1) L'énoncé ne précise pas de quelle filtration est muni l'espace de probabilité, donc on prend la filtration naturelle pour $(X_n)_n$, c'est-à-dire que :

$$\forall n \in \mathbb{N},\ \mathcal{F}_n = \sigma(X_0, \dots, X_n) = \sigma(X_0, \xi_1, \dots, \xi_n).$$

Soit $h : \mathbb{R}^d \to \mathbb{R}$ une fonction borélienne bornée. On vérifie la propriété d'absence de mémoire des chaînes de Markov à espace d'états général (c'est-à-dire non forcément discret, ici $\mathbb{R}^d$) :

$$\begin{aligned}
\mathbb{E}\Big[h\Big(X_{n+1}\Big) \mid X_n, \dots, X_0\Big] &= \mathbb{E}\Big[h\Big(f(X_n, \xi_{n+1})\Big) \mid X_n, \dots, X_0\Big] \\
&= \mathbb{E}\Big[h\Big(f(X_n, \xi_{n+1})\Big) \mid X_n\Big] \\
&= \mathbb{E}\Big[h\Big(f(x, \xi_{n+1})\Big) \mid X_n\Big]_{|x=X_n} \\
&= \mathbb{E}\Big[h\Big(f(x, \xi_1)\Big) \mid X_n\Big]_{|x=X_n} \\
&= K(X_n, h)
\end{aligned}$$

vu que les variables $X_0, \dots, X_n$ sont indépendantes de ξ_{n+1} car fonctions de $\xi_0, \dots, \xi_n$, elles-même indépendantes de ξ_{n+1}. Cela démontre que $(X_n)_n$ est une chaîne de Markov (homogène) de noyau K (indépendant de n).

(2) Une remarque : *a priori*, la notation Kh n'est définie que pour les fonctions (boréliennes) bornées, ce que V n'est pas. Elle est cependant à valeurs positives, donc toutes les quantités en jeu existent, quitte à valoir $+\infty$. Maintenant, l'inégalité de l'énoncé satisfaite par f appliquée à $y = x_0$ et $u = \xi_1$ implique *via* l'inégalité triangulaire [6] que :

$$\begin{aligned}
V\Big(f(x, \xi_1)\Big) &\leq V\Big(f(x_0, \xi_1)\Big) + V\Big(f(x, \xi_1) - f(x_0, \xi_1)\Big) \\
&\leq V\Big(f(x_0, \xi_1)\Big) + \eta(\xi_1) V(x - x_0) \\
&\leq V\Big(f(x_0, \xi_1)\Big) + \eta(\xi_1) V(x) + \eta(\xi_1) V(x_0).
\end{aligned}$$

Par hypothèse ces quantités sont intégrables et en passant à l'espérance on trouve :

$$KV(x) = \mathbb{E}\Big[V\Big(f(x_0, \xi_1)\Big) + \eta(\xi_1) V(x_0)\Big] + \mathbb{E}[\eta(\xi_1)] V(x) = C + \rho V(x),$$

en posant $C := \mathbb{E}\Big[V\Big(f(x_0, \xi_1)\Big) + \eta(\xi_1) V(x_0)\Big]$ et $\rho := \mathbb{E}[\eta(\xi_1)]$. On a bien $C \geq 0$ et, par hypothèse de l'énoncé, $\rho \in]0, 1[$, comme demandé.

(3) Commençons par examiner déjà le cas $n = 2$ pour éviter de s'emméler les pinceaux avec les notations. Par définition $Kh(x) = K(x, h)$ et $K^2 V = K(KV)$ (rappelons que KV est une fonction). On a alors :

6. Plus précisément $V(x) - V(y) \leq V(x - y)$.

$$\begin{aligned}
K^2V(x) &= K(x, KV) \\
&= \mathbb{E}\Big[KV\Big(f(x,\xi_1)\Big)\Big] \\
&\leq \mathbb{E}\Big[\rho V\Big(f(x,\xi_1)\Big) + C\Big] \\
&= \rho KV(x) + C \\
&\leq \rho(\rho V(x) + C) + C \\
&\leq \rho^2 V(x) + C + \rho C
\end{aligned}$$

Cela suggère plus généralement :

$$\forall n \geq 1,\ K^n V(x) \leq \rho^n V(x) + C\sum_{k=0}^{n-1} \rho^k,$$

ce dont le lecteur se convaincra par une récurrence facile (en utilisant que $K^{n+1}V = K(K^nV)$ pour l'hérédité). Enfin on conclut en remarquant que :

$$C\sum_{k=0}^{n-1} \rho^k \leq \frac{C}{1-\rho}$$

puisque $\rho \in]0,1[$.

(4) On sait que $\mathbb{E}_\nu[\|X_n\|] = \nu K^n V = \int_{\mathbb{R}^d} K^n V(x)\mathrm{d}\nu(x)$. Par l'inégalité démontrée à la question précédente, et comme $\rho < 1$, on en déduit :

$$\forall n \in \mathbb{N},\ \mathbb{E}_\nu[\|X_n\|] \leq \rho^n \mathbb{E}_\nu[\|X_0\|] + \frac{C}{1-\rho} \leq \mathbb{E}_\nu[\|X_0\|] + \frac{C}{1-\rho}.$$

(5) Comme $\int V(x)\mathrm{d}\mu_n(x) = \frac{1}{n}\sum_{k=1}^n \mathbb{E}_\nu[\|X_k\|]$, il vient par la majoration précédente (uniforme en n) que :

$$\forall n \in \mathbb{N},\ \int V(x)\mathrm{d}\mu_n(x) \leq \frac{1}{n}\sum_{k=1}^n \Big(\mathbb{E}_\nu[\|X_0\|] + \frac{C}{1-\rho}\Big) = \mathbb{E}_\nu[\|X_0\|] + \frac{C}{1-\rho} < \infty.$$

Le critère de l'exercice 9 permet alors de conclure que la suite de mesures $(\mu_n)_n$ est tendue.

(6)

- La linéarité de l'espérance et le caractère lipschitzien de h et de f permettent d'écrire :

$$\begin{aligned}
\forall x, y \in \mathbb{R}^d,\ |Kh(x) - Kh(y)| &= \Big|\mathbb{E}\Big[h\Big(f(x,\xi_1)\Big) - h\Big(f(y,\xi_1)\Big)\Big]\Big| \\
&\leq \mathbb{E}\Big[\Big|h\Big(f(x,\xi_1)\Big) - h\Big(f(y,\xi_1)\Big)\Big|\Big] \\
&\leq L\mathbb{E}\Big[\Big|f(x,\xi_1) - f(y,\xi_1)\Big|\Big] \\
&\leq L\mathbb{E}\Big[\eta(\xi_1)\|x-y\|\Big] \\
&= \rho L\|x-y\|.
\end{aligned}$$

Cela prouve que Kh est ρL-lipschitzienne. Elle est de plus bornée car h l'est et que $Kh(x) = \mathbb{E}[h(X_1)|X_0 = x]$:

$$\forall x \in \mathbb{R}^d,\ |Kh(x)| \leq \mathbb{E}\Big[\Big|h\Big(f(x,\xi_1)\Big)\Big|\Big] \leq \|h\|_\infty.$$

En fait on peut même prouver (ce n'est pas explicitement demandé dans l'énoncé, mais ça sera indispensable pour la question suivante) que $K^n h$ est bornée par une constante **indépendante de** n. Le raisonnement (et la majoration) est toujours le même :

$$\forall x \in \mathbb{R}^d,\ |K^n h(x)| \leq \mathbb{E}\Big[|h(X_n)||X_0 = x\Big] \leq \|h\|_\infty.$$

- On propose deux preuves : celle vue en cours, de loin la plus simple [7] et une plus classieuse mais qui demande de comprendre ce qu'on fait. En première lecture vous pouvez largement vous contenter de la première. La seconde est intéressante en ce qu'elle fournit un mini-exemple de couplage et peut servir dans d'autres contextes.

  Première preuve : On procède par récurrence. On pose $\forall n \in \mathbb{N}^*,\ \mathcal{P}(n) =$ "$K^n h$ est $\rho^n L$-Lipschitizienne". Le cas $n = 1$ correspond à ce qui vient d'être fait juste avant. Passons à l'hérédité : soit n fixé tel que $\mathcal{P}(n)$ soit vraie. On a $K^{n+1}h(x) = K(x, K^n h) = \mathbb{E}[K^n h(X_1)|X_0 = x]$. En appliquant le raisonnement vu ci-dessus (à $h = K^n h$), on trouve grâce à l'hypothèse de récurrence :

$$\begin{aligned}\forall x, y \in \mathbb{R}^d,\ |K^{n+1}h(x) - K^{n+1}h(y)| &= \Big|\mathbb{E}\Big[K^n h\Big(f(x,\xi_1)\Big) - K^n h\Big(f(y,\xi_1)\Big)\Big]\Big| \\ &\leq \rho^n L \mathbb{E}\Big[\|f(x,\xi_1) - f(y,\xi_1)\|\Big] \\ &\leq \rho^{n+1} L \|x - y\|.\end{aligned}$$

  Seconde preuve : On part de :

$$|K^{n+1}h(x) - K^{n+1}h(y)| = |\mathbb{E}[h(X_{n+1})|X_0 = x] - \mathbb{E}[h(X_{n+1})|X_0 = y]|.$$

  On aimerait bien tout mettre sous le signe espérance (c'est beau), mais ces deux espérances sont différentes à cause des conditionnements $\{X_0 = x\}$ et $\{X_0 = y\}$... Pour contourner ce problème, on va intégrer sous la même probabilité $\mathbb{P}$ deux processus différents : $(X_n^x)_n$ et $(X_n^y)_n$. La notation $(X_n^x)_n$ désigne la chaîne de Markov $(X_n)_n$ initialisée en x. De même pour $(X_n^y)_n$ avec y. Plus formellement :

$$\begin{cases} X_0^x & = x\ \mathbb{P}-\text{p.s.} \\ X_{n+1}^x & = f(X_n^x, \xi_{n+1})\ \mathbb{P}-\text{p.s.} \end{cases}$$

$$\begin{cases} X_0^y & = y\ \mathbb{P}-\text{p.s.} \\ X_{n+1}^y & = f(X_n^y, \xi_{n+1})\ \mathbb{P}-\text{p.s.} \end{cases}$$

  Le point essentiel dans cette définition est que l'on utilise les **mêmes** ξ_n pour définir ces deux chaînes. En particulier elles ne sont pas indépendantes. Mais elles ont même loi

7. Tellement simple que je n'y ai pas pensé au départ.

que $(X_n)_n$ sous la loi intiale δ_z pour $z = x, y$ respectivement [8]. Par conséquent on peut écrire les "presque sûrement" sous la même probabilité $\mathbb{P}$. La suite de la preuve est plus classique :

$$\begin{aligned}
|K^{n+1}h(x) - K^{n+1}h(y)| &= \Big|\mathbb{E}[h(X_{n+1})|X_0 = x] - \mathbb{E}[h(X_{n+1})|X_0 = y]\Big| \\
&= \Big|\mathbb{E}[h(X^x_{n+1}) - \mathbb{E}[h(X^y_{n+1})]\Big| \\
&\leq \mathbb{E}\Big[\Big|h(X^x_{n+1}) - \mathbb{E}[h(X^y_{n+1})\Big|\Big] \\
&\leq L\mathbb{E}\Big[\|X^x_{n+1} - X^y_{n+1}\|\Big] \\
&= L\mathbb{E}\Big[\|f(X^x_n, \xi_{n+1}) - f(X^y_n, \xi_{n+1})\|\Big] \\
&\leq L\rho\mathbb{E}\Big[\|X^x_n - X^y_n\|\Big] \\
&= L\rho\mathbb{E}\Big[\|f(X^x_{n-1}, \xi_n) - f(X^y_{n-1}, \xi_n)\|\Big] \\
&\dots \\
&\leq L\rho^n\mathbb{E}\Big[\|X^x_0 - X^y_0\|\Big] \\
&= L\rho^n\|x - y\|.
\end{aligned}$$

(7)

- Puisque la suite de mesures $(\mu_n)_n$ est tendue, toutes ses sous-suites admettent une sous-suite convergente (*i.e.* toutes ses sous-suites ont au moins une valeur d'adhérence). Soit π l'une de ces valeurs d'adhérence et φ l'extractrice associée : $\pi = \lim_{n\to\infty} \mu_{\varphi(n)}$. Il nous faut prouver que $\pi K = \pi$. Il suffit de montrer que $\pi Kh = \pi h$ pour h bornée lipschitzienne.

  Par convergence dominée, on a que :

$$\lim_{n\to\infty} \mu_{\varphi(n)}h = \lim_{n\to\infty} \int h \mathrm{d}\mu_{\varphi(n)} = \pi h.$$

  De même, puisque Kh est aussi lipschitzienne et bornée :

$$\lim_{n\to\infty} \mu_{\varphi(n)}Kh = \lim_{n\to\infty} \int Kh \mathrm{d}\mu_{\varphi(n)} = \pi Kh.$$

  Mais par définition de μ_n, on a aussi :

$$\mu_{\varphi(n)}Kh = \frac{1}{\varphi(n)} \sum_{k=1}^{\varphi(n)} K^k(Kh) = \mu_{\varphi(n)}h + \frac{1}{\varphi(n)}(K^{\varphi(n)+1}h - Kh).$$

  Ce dernier terme résiduel est de limite nulle car il est borné indépendamment de n : $K^{\varphi(n)+1}h - Kh$ est encore borné (cf la question précédente). Ainsi :

$$\pi Kh = \lim_{n\to\infty} \mu_{\varphi(n)}Kh = \lim_{n\to\infty} \mu_{\varphi(n)}h = \pi h$$

8. Il s'agit d'un exemple (très simple) de couplage de chaînes de Markov.

- Prouvons maintenant que V est π-intégrable. $V \wedge M$ est, à M fixé, une fonction continue bornée, d'où la première convergence dans l'inégalité ci-dessous [9] Comme $\sup_n \int V \mathrm{d}\mu_n$ est finie, on a que :

$$\forall M \in \mathbb{N},\ \int (V \wedge M)\mathrm{d}\pi = \lim_{n\to\infty} \int (V \wedge M)\mathrm{d}\mu_{\varphi(n)} \leq \sup_n \int (V \wedge M)\mathrm{d}\mu_{\varphi(n)} < +\infty.$$

  La borne supérieure de cette inégalité est finie et ne dépend pas de M. On en conclut que V est π-intégrable en appliquant le lemme de Fatou ou par convergence monotone (à la suite de fonctions positives $(V \wedge M)_{M\in\mathbb{N}}$ de limite croissante presque sûre V).

(8) Puisque π_0 et π_1 sont des mesures de probabilité invariante pour K, on a pour h lipschitzienne bornée que :

$$\pi_0 h - \pi_1 h = \pi_0 K^n h - \pi_1 K^n h = \int K^n h \mathrm{d}\pi_0 - \int K^n h \mathrm{d}\pi_1 = \int\int \Big(K^n h(x) - K^n h(y)\Big)\mathrm{d}\pi_0(x)\mathrm{d}\pi_1(y),$$

en utilisant que π_1 et π_2 intègrent à 1 et le théorème de Fubini-Lebesgue à la fonction bornée mesurable $K^n h(x) - K^n h(y)$ pour réécrire l'intégrale double. On conclut par l'inégalité triangulaire.

(9) Soient π_1 et π_2 deux mesures de probabilités invariantes pour K et pour lesquelles V est intégrable. On combine le résultat précédent avec celui de la question **(6)**, ce qui donne :

$$\forall n \in \mathbb{N},\ |\pi_0 h - \pi_1 h| \leq L\rho^n \int\int \|x - y\| \mathrm{d}\pi_1(x)\mathrm{d}\pi_2(y).$$

Cette dernière intégrale est finie car :

$$\int\int \|x - y\| \mathrm{d}\pi_1(x)\mathrm{d}\pi_2(y) \leq \int V \mathrm{d}\pi_1 + \int V \mathrm{d}\pi_2,$$

et chacune de ces intégrales est finie car on a supposé que V était π_1- et π_2-intégrable. En faisant tendre n vers l'infini, puisque $\rho < 1$, on en déduit que $\pi_1 h = \pi_2 h$ quelque soit h lipschitzienne bornée. Cela suffit pour conclure que $\pi_1 = \pi_2$.

(10) Ce type de raisonnement est très classique en analyse fonctionnelle et à retenir. On sait que toute sous-suite de $(\mu_n)_n$ admet au moins une valeur d'adhérence (par Prokhorov), et que ces valeurs d'adhérence sont des mesures de probabilités invariantes pour lesquelles V est intégrable. La question précédente montre alors qu'une seule valeur d'adhérence est possible (qu'on appelle π).

Supposons maintenant que μ_n ne converge pas faiblement vers π. Alors on peut trouver une fonction test h (disons lipschitzienne bornée) telle que $\int h \mathrm{d}\mu_n$ ne converge pas vers $\int h \mathrm{d}\pi$. En particulier on peut trouver un $\varepsilon > 0$ tel qu'une infinité de termes de $\Big(\int h \mathrm{d}\mu_n\Big)$ soient à distance strictement supérieure à ε de $\int h \mathrm{d}\pi$. On construit ainsi une sous-suite $(\mu_{\varphi(n)})_n$ telle que :

$$\forall n \in \mathbb{N},\ \Big|\int h \mathrm{d}\mu_{\varphi(n)} - \int h \mathrm{d}\pi\Big| > \varepsilon.$$

9. Qu'on peut noter aussi : $\lim_{n\to\infty} \mu_{\varphi(n)}(V \wedge M) = \pi(V \wedge M) = \mathbb{E}_\pi[V(X_0) \wedge M]$.

Mais une telle sous-suite ne peut exister, car on peut encore en extraire une nouvelle sous-suite convergeant faiblement vers π. On aurait alors $\varepsilon < 0$ en passant à la limite ! Cela conclut.

(11) Par la question **(3)**, on a :

$$K^n(V \wedge M) \leq (K^n V) \wedge M \leq \Big(\rho^n V + \frac{C}{1-\rho}\Big) \wedge M \ \pi - \text{presque sûrement.}$$

Il reste à intégrer contre π pour conclure.

(12) On applique d'abord le théorème de convergence dominée pour faire tendre n vers l'infini dans l'intégrale (la domination est donnée par la fonction constante π-intégrable $C/(1-\rho)$ (pour M fixé assez grand)) :

$$\lim_{n\to\infty} \int \Big(\rho^n V + \frac{C}{1-\rho}\Big) \wedge M \mathrm{d}\pi = \int \frac{C}{1-\rho} \wedge M \mathrm{d}\pi = \frac{C}{1-\rho} \wedge M \leq \frac{C}{1-\rho}.$$

Donc par la question précédente $\int V \wedge M \mathrm{d}\pi$ est bornée par la constante $C/(1-\rho)$, qui est indépendante de M ; on en déduit la majoration attendue pour $\int V \mathrm{d}\pi = \lim\limits_{M\to\infty} \int V \wedge M \mathrm{d}\pi$ (par convergence monotone par exemple).

MACS 203b - Corrections

Bruno Costacèque

18 janvier 2023

Exercice 12

(1) Un estimateur $\hat{\theta}_n$ (ou plutôt une suite d'estimateurs $(\hat{\theta}_n)_n$) est dit consistant s'il converge en probabilité vers le paramètre θ à estimer. Les hypothèses de l'énoncé assurent que la suite $(X_n)_n$ est constituée de variables i.i.d. intégrables. La loi forte des grands nombres donne alors que $(\overline{X}_n)_n$ converge presque sûrement vers $\mathbb{E}[X_1] = \mu$, et donc en probabilité. $(\overline{X}_n)_n$ est bien une suite consistante d'estimateurs.

(2) Il s'agit du cas d'école par excellence de recherche d'intervalle de confiance. On s'appuie sur le théorème central limite qui nous donne :

$$\sqrt{n}\frac{\overline{X}_n - \mu}{\sigma} \underset{n\to\infty}{\Longrightarrow} \mathcal{N}(0,1).$$

Nous noterons dans le reste du TD (c'est une notation standard) $\Phi(x)$ la fonction de répartition de la loi normale centrée réduite. Puisque la fonction valeur absolue est continue, et que la convergence en loi implique la convergence des fonctions de répartition en chaque point de continuité de Φ (partout donc), il vient que [1] :

$$\forall x \in \mathbb{R},\ \mathbb{P}\Big(\sqrt{n}\Big|\frac{\overline{X}_n - \mu}{\sigma}\Big| \leq x\Big) \underset{n\to\infty}{\longrightarrow} 2\Phi(x) - 1.$$

De ce résultat, on cherche à en déduire un intervalle (aléatoire) qui contiendra μ avec une probabilité (d'au moins) 95%. Pour cela on réécrit :

$$\begin{aligned}
\mathbb{P}\Big(\sqrt{n}\Big|\frac{\overline{X}_n - \mu}{\sigma}\Big| \leq x\Big) &= \mathbb{P}\Big(-x \leq \sqrt{n}\frac{\overline{X}_n - \mu}{\sigma} \leq x\Big) \\
&= \mathbb{P}\Big(-\frac{\sigma x}{\sqrt{n}} \leq \overline{X}_n - \mu \leq \frac{\sigma x}{\sqrt{n}}\Big) \\
&= \mathbb{P}\Big(\overline{X}_n - \sigma\frac{x}{\sqrt{n}} \leq \mu \leq \overline{X}_n + \sigma\frac{x}{\sqrt{n}}\Big) \\
&= \mathbb{P}\Big(\Big[\overline{X}_n - \sigma\frac{x}{\sqrt{n}}, \overline{X}_n + \sigma\frac{x}{\sqrt{n}}\Big] \ni \mu\Big)
\end{aligned}$$

1. Si $Z \hookrightarrow \mathcal{N}(0,1)$, alors :

$$\mathbb{P}(|Z| \leq x) = \mathbb{P}(-x \leq Z \leq x) = \Phi(x) - \Phi(-x) = \Phi(x) - (1 - \Phi(x)) = 2\Phi(x) - 1.$$

On choisit alors x tel que $2\Phi(x) - 1 = 0.95$. Un calcul immédiat montre que $x = q_{0.975}$ convient (il s'agit du quantile[2] de la loi normale à l'ordre 0.975). Finalement **un** intervalle de confiance **asymptotique** à l'ordre 95% est :

$$\mathcal{I}_n := \Big[\overline{X}_n - \sigma\frac{q_\alpha}{\sqrt{n}}, \overline{X}_n + \sigma\frac{q_\alpha}{\sqrt{n}}\Big].$$

(3) Ce qui précède fonctionnait car on supposait connue la variance σ^2 des X_i. L'intervalle précédent devient inutile si on a pas accès à cette information. L'idée naturelle sera alors de remplacer σ par un estimateur *ad hoc*. Comme $\sigma^2 = \mathbb{E}[(X-\mu)^2]$, le choix le plus naturel qui vienne à l'esprit est une moyenne empirique, c'est-à-dire qu'on propose :

$$S_n^2 := \frac{1}{n}\sum_{i=1}^n \Big(X_i - \overline{X}_n\Big)^2 = \frac{1}{n}\sum_{i=1}^n X_i^2 + \overline{X}_n^2 - \overline{X}_n^2 = \frac{1}{n}\sum_{i=1}^n X_i^2 - \overline{X}_n^2.$$

On a remplacé μ par la moyenne empirique puisque μ est toujours supposé inconnu. La loi forte des grands nombres appliquée aux variables aléatoires i.i.d. et intégrables X_i^2 montre alors que :

$$S_n^2 \xrightarrow[n\to\infty]{\text{p.s.}} \mathbb{E}[X_1^2] - \mathbb{E}[X_1]^2 = \sigma^2.$$

Cela prouve la consistence de $(S_n^2)_n$. Faisons une remarque au sujet de cet estimateur, qui expliquera l'apparition d'un facteur $n-1$ au dénominateur à la question **(6)**. Bien que "naturel", il est biaisé. Cela résulte essentiellement du fait que le carré de la moyenne empirique n'a aucun raison de valoir le carré de l'espérance μ. Plus précisément, en posant $Y_i := X_i - \mu$ (qui est donc centrée) :

$$\begin{aligned}
\mathbb{E}[S_n^2] &= \mathbb{E}\Big[\frac{1}{n}\sum_{i=1}^n \Big(X_i - \overline{X}_n\Big)^2\Big] \\
&= \mathbb{E}\Big[\frac{1}{n}\sum_{i=1}^n \Big((X_i-\mu) - (\overline{X}_n - \mu)\Big)^2\Big] \\
&= \mathbb{E}\Big[\frac{1}{n}\sum_{i=1}^n (X_i-\mu)^2\Big] + \mathbb{E}\Big[\overline{Y}_n^2 - 2\overline{Y}_n^2\Big] \\
&= \mathbb{E}\Big[\frac{1}{n}\sum_{i=1}^n (X_i-\mu)^2\Big] - \mathbb{E}\Big[\overline{Y}_n^2\Big] \\
&= \sigma^2 - \frac{1}{n^2}\mathbb{E}\Big[\Big(\sum_{i=1} Y_i\Big)^2\Big] \\
&= \sigma^2 - \frac{1}{n^2}\mathbb{E}\Big[\sum_{i=1} Y_i^2\Big] \\
&= \sigma^2 - \frac{1}{n}\sigma^2 \\
&= \frac{n-1}{n}\sigma^2,
\end{aligned}$$

2. Par définition, pour $\alpha \in]0,1[$, le quantile à l'ordre α de la loi normale q_α satisfait :

$$\Phi(q_\alpha) = \alpha.$$

et le passage du "carré de la somme" à la "somme des carrés" est justifié par le fait que les Y_i sont centrées et indépendantes (elles forment un système orthogonal pour le produit scalaire $\langle X, Y\rangle_{\mathbb{L}^2(\Omega)} := \mathbb{E}[XY]$), ce qu'on vérifie facilement à la main. En conclusion,

$$\sigma_n^2 := \frac{1}{n-1}\sum_{i=1}^{n}\Big(X_i - \overline{X}_n\Big)^2$$

est un estimateur non biaisé de σ^2.

(4) On applique le lemme de Slutsky : $(S_n^2)_n$ converge en probabilité vers la constante σ^2 et $\sqrt{n}(\overline{X}_n - \mu)$ converge en loi vers $\mathcal{N}(0,\sigma^2)$. Par Slutsky :

$$\Big(S_n^2, \sqrt{n}(\overline{X}_n - \mu)\Big) \underset{n\to\infty}{\Longrightarrow} \Big(\delta_{\sigma^2}, \mathcal{N}(0,\sigma^2)\Big),$$

et donc $T_n \underset{n\to\infty}{\Longrightarrow} \mathcal{N}(0,1)$, par continuité de $x \mapsto x^{-1/2}$ sur $\mathbb{R}_+^* \ni \sigma^2$.

(5) Grâce à la question précédente, on peut prendre le même intervalle de confiance [3] qu'en **(2)**, mais en remplaçant σ par $\sqrt{S_n^2}$:

$$\mathcal{J}_n := \left[\overline{X}_n - \sqrt{S_n^2}\frac{q_\alpha}{\sqrt{n}}, \overline{X}_n + \sqrt{S_n^2}\frac{q_\alpha}{\sqrt{n}}\right].$$

(6) On part de l'expression vue à la fin de la question **(3)** :

$$S_n^2 = \frac{1}{n}\sum_{i=1}^{n}\Big((X_i-\mu) - (\overline{X}_n - \mu)\Big)^2 = \frac{1}{n}\sum_{i=1}^{n} Y_i^2 - \overline{Y}_n^2,$$

L'intérêt de cette expression est que l'on manipule des variables centrées, ce qui permet d'écrire grâce à la loi forte des grands nombres :

$$\sqrt{n}\overline{Y}_n^2 = (\sqrt{n}\overline{Y}_n)\overline{Y}_n \underset{n\to\infty}{\Longrightarrow} \delta_0,$$

là encore grâce à Slutsky. Par le théorème central limite (l'hypothèse de l'énoncé assure que Y_i^2 est encore de carré intégrable) et le lemme de Slutsky ($(\sqrt{n}\overline{Y}_n)_n$ converge en loi vers une loi normale et $(\overline{Y}_n)_n$ converge presque sûrement vers $\mathbb{E}[Y_1] = 0$). Finalement, toujours par Slutsky [4] (dont vous réalisez l'importance maintenant j'espère !) :

$$\begin{aligned}
\sqrt{n}(S_n^2 - \sigma^2) &= \sqrt{n}\Big(\frac{1}{n}\sum_{i=1}^{n} Y_i^2 - \sigma^2\Big) - \sqrt{n}\,\overline{Y}_n^2 \\
&= \sqrt{n}\Big(\frac{1}{n-1}\sum_{i=1}^{n} Y_i^2 - \sigma^2\Big) - \frac{\sqrt{n}}{n(n-1)}\sum_{i=1}^{n} Y_i^2 - \sqrt{n}\,\overline{Y}_n^2 \\
&= \sqrt{n}\Big(\frac{1}{n-1}\sum_{i=1}^{n} Y_i^2 - \sigma^2\Big) - \frac{1}{\sqrt{n}}\Big(\frac{1}{(n-1)}\sum_{i=1}^{n} Y_i^2\Big) - \sqrt{n}\,\overline{Y}_n^2 \\
&\underset{n\to\infty}{\Longrightarrow} \mathcal{N}(0, \mathbb{V}(Y_1^2)),
\end{aligned}$$

vu que $\mathbb{E}[Y_1^2] = \sigma^2$.

3. Bien sûr ce nouvel intervalle de confiance est *a priori* moins précis que le précédent, au sens où il faudra un nombre n de données plus important pour avoir un encadrement fin de μ.

4. Car $(\sqrt{n}\overline{Y}_n^2)_n$ converge en loi vers 0, une constante, donc la convergence a aussi lieu en probabilité.

Exercice 13

(1) L'estimateur des moindres carrés s'écrit :

$$\hat{\boldsymbol{\beta}}_n = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y},$$

où l'on note $\mathbf{Y} := (Y_1, \cdots, Y_n)^\top \in \mathbb{R}^n$ et $\mathbf{X} := [\mathbf{x}_1, \cdots, \mathbf{x}_n]^\top \in \mathcal{M}_{n,p}(\mathbb{R})$ (les colonnes de cette matrice correspondent aux variables explicatives et ses lignes aux échantillons observés ; cette convention est très courante). Pour coller d'avantage à l'énoncé, on peut réécrire cette expression autrement :

$$\hat{\boldsymbol{\beta}}_n = \Big(\sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i^\top \Big)^{-1} \sum_{j=1}^n \mathbf{x}_j Y_j = C_n^{-1} \Big(\frac{1}{n} \sum_{j=1}^n \mathbf{x}_j Y_j \Big),$$

en notant $C_n := \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i^\top$.

(2) Par ce qui précède, et comme $Y_i = \mathbf{x}_i^\top \beta + \varepsilon_i$, il vient :

$$\begin{aligned}
\hat{\boldsymbol{\beta}}_n &= C_n^{-1} \Big(\frac{1}{n} \sum_{j=1}^n \mathbf{x}_j Y_j \Big) \\
&= C_n^{-1} \Big(\frac{1}{n} \sum_{j=1}^n \mathbf{x}_j \mathbf{x}_j^\top \beta + \varepsilon_j \Big) \\
&= C_n^{-1} C_n \beta + C_n^{-1} \Big(\frac{1}{n} \sum_{j=1}^n \mathbf{x}_j \varepsilon_j \Big) \\
&= \beta + C_n^{-1} \Big(\frac{1}{n} \sum_{j=1}^n \mathbf{x}_j \varepsilon_j \Big)
\end{aligned}$$

Par l'hypothèse ii) de l'énoncé, $(C_n)_n$ converge vers une matrice symétrique définie positive C. Mais l'application $\mathbf{GL}(n, \mathbb{R}) \to \mathbf{GL}(n, \mathbb{R})$ qui associe à une matrice son inverse est continue (on le prouve à l'aide de la formule de Cramer par exemple), donc $(C_n^{-1})_n$ converge vers C^{-1}. De plus, en notant $x_j^{(k)}$ la $k-$ème coordonnée du vecteur $\mathbf{x}_j$, on a que :

$$C_n^{-1} \Big(\frac{1}{n} \sum_{j=1}^n \mathbf{x}_j \varepsilon_j \Big) = C_n^{-1} \Big(\frac{1}{n} \sum_{j=1}^n x_j^{(1)} \varepsilon_j, \ldots, \sum_{j=1}^n x_j^{(p)} \varepsilon_j \Big)^\top =: C_n^{-1} \mathbf{Z}_n$$

Remarquons que :

$$\begin{aligned}\forall k \in [\![1,p]\!],\ \mathbb{V}\Big(\frac{1}{n}\sum_{j=1}^{n} x_j^{(k)}\varepsilon_j\Big) &= \frac{1}{n^2}\sum_{j=1}^{n}(x_j^{(k)})^2\mathbb{V}(\varepsilon_j)\\ &= \frac{1}{n^2}\sum_{j=1}^{n}(x_j^{(k)})^2\\ &= \frac{1}{n^2}\sum_{j=1}^{n}(x_j^{(k)})^2\\ &\leq \frac{1}{n^2}\sum_{j=1}^{n}\|x_j^{(k)}\|^2\\ &\leq \frac{1}{n^2}\sum_{j=1}^{n}\max_{1\leq i\leq n}\|x_i^{(k)}\|^2\\ &= \frac{1}{n}\max_{1\leq i\leq n}\|x_i^{(k)}\|^2,\end{aligned}$$

et cette dernière quantité tend vers 0 par hypothèse. Donc les p coordonnées du vecteur $\mathbf{Z}_n$ tendent vers $\mathbf{0}_{\mathbb{R}^p}$ dans $\mathbb{L}^2(\Omega)$ (c'est-à-dire en moyenne quadratique [5]), et donc en probabilité et en loi. Finalement, encore (et toujours...) par Slutsky, on en déduit que :

$$C_n^{-1}\Big(\frac{1}{n}\sum_{j=1}^{n} x_j^{(1)}\varepsilon_j,\dots,\sum_{j=1}^{n} x_j^{(p)}\varepsilon_j\Big)^\top \underset{n\to\infty}{\Longrightarrow} \delta_{C^{-1}\mathbf{0}_{\mathbb{R}^p}} = \delta_{\mathbf{0}_{\mathbb{R}^p}}$$

et donc (vous reprendrez un peu de Slutsky avec votre Slutsky ?) que :

$$\hat{\boldsymbol{\beta}}_n \underset{n\to\infty}{\Longrightarrow} \hat{\boldsymbol{\beta}}.$$

(3) On va chercher à appliquer le théorème 2.23 de votre cours, ce qui suppose de vérifier ses quatre hypothèses. Pour cela, posons

$$\forall j \in [\![1,n]\!],\ \mathbf{X}_{j,n} := \Big(\frac{1}{\sqrt{n}}\varepsilon_j x_j^{(1)},\dots,\frac{1}{\sqrt{n}}\varepsilon_j x_j^{(p)}\Big) = \frac{1}{\sqrt{n}}\varepsilon_j\mathbf{x}_j.$$

Ces vecteurs aléatoires sont indépendants et centrés, ce qui donne les conditions (i) et (ii). Il reste à vérifier la condition (iii) (dite de Lindebergh) et la condition (iv). Pour la condition (iv), on a :

$$\mathbb{C}\mathrm{ov}(\mathbf{X}_{j,n}) = \frac{1}{n}\mathbf{x}_j\mathbf{x}_j^\top,$$

de sorte que les matrices de covariance des $\mathbf{X}_{j,n}$, qu'on note $C_{j,n}$, vérifient :

$$\sum_{j=1}^{n} C_{j,n} = \frac{1}{n}\sum_{j=1}^{n}\mathbf{x}_j\mathbf{x}_j^\top = C_n \underset{n\to\infty}{\Rightarrow} C,$$

par hypothèse de l'énoncé. Vérifions la condition de Lindebergh. Soit $\varepsilon > 0$ et soit $\delta > 0$. Puisque les ε_j ont tous même loi, on peut écrire :

5. Rappelons que $\mathbb{V}(X) = \|X - \mathbb{E}[X]\|^2_{\mathbb{L}^2(\Omega)}$.

$$\begin{aligned}\sum_{j=1}^{n}\mathbb{E}\Big[\|\mathbf{X}_{j,n}\|^2\mathbb{1}_{\{\|\mathbf{X}_{j,n}\|\geq\varepsilon\}}\Big] &= \frac{1}{n}\sum_{j=1}^{n}\mathbb{E}\Big[\|\mathbf{x}_j\|^2\varepsilon_j^2\mathbb{1}_{\{\|\mathbf{X}_{j,n}\|\geq\varepsilon\}}\Big]\\ &= \frac{1}{n}\sum_{j=1}^{n}\mathbb{E}\Big[\|\mathbf{x}_j\|^2\varepsilon_j^2\mathbb{1}_{\{\|\mathbf{X}_{j,n}\|^2\geq\varepsilon^2\}}\Big]\\ &= \frac{1}{n}\sum_{j=1}^{n}\mathbb{E}\Big[\|\mathbf{x}_j\|^2\varepsilon_j^2\mathbb{1}_{\{\frac{1}{n}\|\mathbf{x}_j\|^2\varepsilon_j^2\geq\varepsilon^2\}}\Big]\\ &= \frac{1}{n}\sum_{j=1}^{n}\mathbb{E}\Big[\|\mathbf{x}_j\|^2\varepsilon_1^2\mathbb{1}_{\{\frac{1}{n}\|\mathbf{x}_j\|^2\varepsilon_1^2\geq\varepsilon^2\}}\Big]\end{aligned}$$

On note :

$$h(n) := \frac{1}{n}\max_{1\leq j\leq n}\|\mathbf{x}_j\|^2.$$

Par hypothèse de l'énoncé, ce terme tend vers zéro quand n tend vers l'infini. De plus on peut majorer dans l'indicatrice le terme $\|\mathbf{x}_j\|^2$ par $nh(n)$ (par définition de $h(n)$!) :

$$\begin{aligned}\sum_{j=1}^{n}\mathbb{E}\Big[\|\mathbf{X}_{j,n}\|^2\mathbb{1}_{\{\|\mathbf{X}_{j,n}\|\geq\varepsilon\}}\Big] &\leq \sum_{j=1}^{n}\mathbb{E}\Big[\|\mathbf{x}_j\|^2\varepsilon_1^2\mathbb{1}_{\{\frac{1}{n}\|\mathbf{x}_j\|^2\varepsilon_1^2\geq\varepsilon^2\}}\Big]\\ &\leq \frac{1}{n}\sum_{j=1}^{n}\mathbb{E}\Big[\|\mathbf{x}_j\|^2\varepsilon_1^2\mathbb{1}_{\{h(n)\varepsilon_1^2\geq\varepsilon^2\}}\Big]\\ &= \mathbb{E}\Big[\varepsilon_1^2\mathbb{1}_{\{h(n)\varepsilon_1^2\geq\varepsilon^2\}}\Big]\Big(\frac{1}{n}\sum_{j=1}^{n}\|\mathbf{x}_j\|^2\Big)\end{aligned}$$

Enfin cette dernière moyenne converge vers $\mathrm{tr}(C)$: pour le voir, il suffit d'appliquer l'hypothèse (ii) de l'énoncé en se souvenant que :

$$\|\mathbf{x}_j\|^2 = \mathrm{tr}(\|\mathbf{x}_j\|^2) = \mathrm{tr}(\mathbf{x}_j^\top\mathbf{x}_j) = \mathrm{tr}(\mathbf{x}_j\mathbf{x}_j^\top).$$

Puisque $1/h(n)$ tend vers l'infini quand n tend vers l'infini, et puisque ε_1^2 est une variable aléatoire intégrable, on a par convergence dominée que :

$$\lim_{n\to\infty}\mathbb{E}\Big[\varepsilon_1^2\mathbb{1}_{\{h(n)\varepsilon_1^2\geq\varepsilon^2\}}\Big] = \lim_{n\to\infty}\mathbb{E}\Big[\varepsilon_1^2\mathbb{1}_{\{\varepsilon_1^2\geq\frac{\varepsilon^2}{h(n)}\}}\Big] = 0.$$

On en conclut que la condition de Lindebergh est bien vérifiée, et avec la normalité asymptotique de $\hat{\boldsymbol{\beta}}_n$

Exercice 15

(1) On est sous les hypothèses de la loi forte des grands nombres, donc par continuité de exp et de $x \mapsto \log|x|$ en $\mu \neq 0$:

$$e^{\overline{X}_n} \underset{n\to\infty}{\longrightarrow} e^{\mu} \text{ et } \log|\overline{X}_n| \underset{n\to\infty}{\longrightarrow} \log|\mu| \text{ p.s.}$$

(2) Il s'agit d'une application immédiate de la delta-méthode (théorème 3.6 de votre cours). Avec les mêmes notations, on prend $g = \exp$ (resp. $g = x \mapsto \log|x|$), $r_n = \sqrt{n}$ et $x = e^{\mu}$ (resp. $x = \log|\mu|$). Ces deux fonctions sont bien différentiables en μ et la condition (iii) est une conséquence directe du théorème central limite. On trouve successivement :

$$\sqrt{n}\Big(e^{\overline{X}_n} - e^{\mu}\Big) \underset{n\to\infty}{\Longrightarrow} e^{\mu}\mathcal{N}(0,\sigma^2) = \mathcal{N}(0, e^{2\mu}\sigma^2),$$

$$\sqrt{n}\Big(\log|\overline{X}_n| - \log|\mu|\Big) \underset{n\to\infty}{\Longrightarrow} \frac{1}{\mu}\mathcal{N}(0,\sigma^2) = \mathcal{N}\Big(0, \frac{\sigma^2}{\mu^2}\Big).$$

(3) La suite diverge presque sûrement vers $+\infty$.

Exercice 16

(1) Par continuité de $x \mapsto \sqrt{x}$:

$$\hat{\theta}_n = \frac{N_1}{n} + \frac{1}{2}\frac{N_2}{n} \underset{n\to\infty}{\xrightarrow{\text{p.s.}}} \theta^2 + \frac{1}{2}2\theta(1-\theta) = \theta$$

$$\text{et } \frac{N_1}{n} \underset{n\to\infty}{\xrightarrow{\text{p.s.}}} \theta^2$$

Donc $(\hat{\theta}_n)_n$ et $(N_1/n)_n$ sont bien des suites d'estimateurs fortement consistantes, de θ et θ^2 respectivement.

- La normalité asymptotique de $(\hat{\theta}_n)_n$ est une conséquence du théorème central limite, appliqué aux variables aléatoires i.i.d. :

$$Y_k := \mathbb{1}_{\{X_k=1\}} + \frac{1}{2}\mathbb{1}_{\{X_k=2\}},$$

d'espérance $\mathbb{E}[Y_1] = \theta$ et de variance [6] :

6. On se souviendra que si A et B sont deux événements, $X = \mathbb{1}_A$ et $Y = \mathbb{1}_B$, alors :

$$\mathbb{C}\text{ov}(X,Y) = \mathbb{P}(A \cap B) - \mathbb{P}(A)\mathbb{P}(B).$$

En particulier si $A \cap B = \emptyset$, alors $\mathbb{C}\text{ov}(X,Y) = -\mathbb{P}(A)\mathbb{P}(B)$.

$$\begin{aligned}
\mathbb{V}(Y_1) &= \mathbb{V}(\mathbb{1}_{\{X_k=1\}}) + \mathbb{V}\Big(\frac{1}{2}\mathbb{1}_{\{X_k=2\}}\Big) + 2\mathbb{C}\mathrm{ov}\Big(\mathbb{1}_{\{X_k=1\}}, \frac{1}{2}\mathbb{1}_{\{X_k=2\}}\Big) \\
&= \theta^2(1-\theta^2) + \frac{1}{4}\Big(2\theta(1-\theta)(1-2\theta(1-\theta))\Big) - \theta^2(2\theta(1-\theta)) \\
&= \theta^2(1-\theta^2) + \frac{1}{2}\Big((\theta-\theta^2)(1-2\theta+2\theta^2)\Big) - 2\theta^3(1-\theta) \\
&= \theta^2 - \theta^4 + \frac{1}{2}(\theta - 2\theta^2 + 2\theta^3 - \theta^2 + 2\theta^3 - 2\theta^4) - 2\theta^3 + 2\theta^4 \\
&= \theta^4 - 2\theta^3 + \theta^2 + \frac{1}{2}(\theta - 3\theta^2 + 4\theta^3 - 2\theta^4) \\
&= -\frac{1}{2}\theta^2 + \frac{1}{2}\theta \\
&= \frac{1}{2}\theta(1-\theta)
\end{aligned}$$

(on savait déjà que cette expression devait s'annuler en 0 et en 1). Cela dit, le théorème central limite donne la normalité asymptotique de $(\hat{\theta}_n)_n$:

$$\sqrt{n}\Big(\hat{\theta}_n - \theta\Big) \underset{n\to\infty}{\Longrightarrow} \mathcal{N}\Big(0, \frac{1}{2}\theta(1-\theta)\Big).$$

- La normalité asymptotique de N_1/n est une conséquence directe du théorème central limite :

$$\sqrt{n}\Big(\frac{N_1}{n} - \theta^2\Big) \underset{n\to\infty}{\Longrightarrow} \mathcal{N}(0, \theta^2(1-\theta^2)).$$

(2) Tout d'abord on a par la loi forte des grands nombres :

$$\tilde{\theta}_n \underset{n\to\infty}{\overset{\text{p.s.}}{\longrightarrow}} \sqrt{\theta^2} = \theta.$$

Pour avoir la normalité asymptotique de $(\tilde{\theta}_n)_n$, on va appliquer la delta-méthode à la fonction $x \mapsto \sqrt{x}$. Cette dernière est bien dérivable en θ^2, puisque θ est supposé non nul. On en déduit alors :

$$\sqrt{n}\Big(\tilde{\theta}_n - \theta\Big) \underset{n\to\infty}{\Longrightarrow} \frac{1}{2\sqrt{\theta^2}}\mathcal{N}\Big(0, \theta^2(1-\theta^2)\Big) = \mathcal{N}\Big(0, (1-\theta)\Big(\frac{1+\theta}{4}\Big)\Big)$$

(3) Précisons d'abord que ce qu'on entend par variance asymptotique est la variance de la loi normale limite qui apparaît lorsqu'on prouve la normalité asymptotique d'une suite d'estimateurs (et **surtout pas** la limite de la suite des variances, qui n'a aucune raison de converger !). Ici on a :

$$\hat{\sigma}^2(\theta) = \frac{1}{2}\theta(1-\theta) \text{ et } \tilde{\sigma}^2(\theta) = (1-\theta)\Big(\frac{1+\theta}{4}\Big),$$

en notant $\hat{\sigma}^2$ la variance asymptotique de $(\hat{\theta}_n)_n$ et $\tilde{\sigma}^2$ la variance asymptotique de $(\tilde{\theta}_n)_n$ (qui sont toutes deux des fonctions de θ). On a alors pour $\theta \in]0,1[$:

$$\begin{aligned}\hat{\sigma}^2(\theta) \leq \tilde{\sigma}^2(\theta) &\Leftrightarrow \frac{1}{2}\theta(1-\theta) \leq (1-\theta)\Big(\frac{1+\theta}{4}\Big)\\ &\Leftrightarrow 2\theta \leq 1+\theta\\ &\Leftrightarrow \theta \leq 1,\end{aligned}$$

et donc $(\tilde{\theta}_n)_n$ possède toujours une variance asymptotique supérieure à celle de $(\hat{\theta}_n)_n$, quelque soit la valeur de θ.

Remarque 1. *Une telle analyse a t-elle un sens en général ? $\hat{\sigma}^2(\theta)$ et $\tilde{\sigma}^2(\theta)$ auraient pu avoir des expressions moins simples, et la comparaison aurait pu dépendre des valeurs de θ. Mais on ne connaît pas θ, donc comment pourrait-on en choisir un estimateur selon sa valeur ? ! En réalité il n'est pas rare qu'on dispose d'informations supplémentaires sur le paramètre θ qui peuvent donner un encadrement approximatif de sa vraie valeur. Par exemple si l'on lance une pièce plusieurs fois, il est assez facile de déterminer si elle est fortement biaiséee ou non en comptant le nombre de "face". De même, à moins d'avoir une variance très grande, une variable aléatoire de loi gaussienne reste assez proche de sa moyenne (les queues de cette loi décroissent très vite), etc. Morale : le choix d'un bon estimateur dépend donc fortement du modèle sous-jacent et il est important de le prendre en compte au maximum, plutôt que d'appliquer des recettes toutes faites sans réfléchir.*

(4) Comme toujours, le problème pour déterminer la précision asymptotique d'un estimateur est que sa variance asymptotique dépend souvent du paramètre qu'on estime. Cela rend inutile le calcul d'un intervalle de confiance, puisque ses bornes dépendraient du paramètre inconnu. L'idée dans cette question est de trouver une transformation g de N_1/n telle que la variance asymptotique du nouvel estimateur $g(N_1/n)$ soit indépendante de θ. Cela suppose en particulier que g soit dérivable en θ^2, de dérivée non nulle en θ^2 et telle que :

$$(g'(\theta^2))^2\theta^2(1-\theta^2)$$

soit indépendante de θ, disons égale à 1. On doit donc trouver g **bijective** telle que :

$$g'(x) = \frac{1}{\sqrt{x(1-x)}}.$$

Une connaissance élémentaire des fonctions trigonométriques réciproques (ou de Wolfram Alpha pour les plus flemmards) donne :

$$g(x) = -\arcsin(-2x+1).$$

Cette fonction est croissante (pour $x \in]0,1[$), d'inverse $g^{-1}(y) = (1+\sin y)/2$ et est bien une primitive de la fonction $x \mapsto \sqrt{x(1-x)}$. Par construction, grâce à la delta-méthode :

$$\sqrt{n}\Big(g\Big(\frac{N_1}{n}\Big) - g(\theta^2)\Big) \underset{n\to\infty}{\Longrightarrow} \mathcal{N}(0,1).$$

Exactement comme à l'exercice 12, on construit un intervalle de confiance asymptotique pour θ^2. Posons $\overline{N_{1,n}} := N_1/n$. Quelque soit $x \in \mathbb{R}$, on a par croissance et bijectivité de g^{-1} sur $]-\pi/2, \pi/2[$:

$$\begin{aligned}\mathbb{P}\Big(\sqrt{n}|g(\overline{N_{1,n}}) - g(\theta^2)| \leq x\Big) &= \mathbb{P}\Big(-\frac{x}{\sqrt{n}} \leq g(\overline{N_{1,n}}) - g(\theta^2) \leq \frac{x}{\sqrt{n}}\Big) \\ &= \mathbb{P}\Big(g(\overline{N_{1,n}}) - \frac{x}{\sqrt{n}} \leq g(\theta^2) \leq g(\overline{N_{1,n}}) + \frac{x}{\sqrt{n}}\Big) \\ &= \mathbb{P}\Big(g^{-1}\Big(\Big[g(\overline{N_{1,n}}) - \frac{x}{\sqrt{n}}, g(\overline{N_{1,n}}) + \frac{x}{\sqrt{n}}\Big]\Big) \ni \theta^2\Big).\end{aligned}$$

C'est-à-dire qu'on prend comme intervalle de confiance de θ^2 :

$$\mathcal{J}_n := \Big[\frac{1}{2}\Big(1 + \sin\Big(g(\overline{N_{1,n}}) - \frac{x}{\sqrt{n}}\Big)\Big), \frac{1}{2}\Big(1 + \sin\Big(g(\overline{N_{1,n}}) + \frac{x}{\sqrt{n}}\Big)\Big)\Big]$$

Les bornes de cet intervalle ont le bon goût d'être positives, donc on peut passer à la racine carrée (qui est croissante) pour en déduire un intervalle de confiance de θ. Le résultat obtenu étant déjà asse moche comme ça, le soin est laissé au lecteur d'écrire l'intervalle explicitement... Finalement on prend pour x le quantile de la loi normale centrée **réduite** qui va bien (cf exercice 12) pour avoir le niveau de confiance recherché, (par exemple $x = q_{0.975}$ si l'on veut un niveau de confiance à 0.95 = 2*0.975-1 pourcent).

Remarque 2. *Cette méthode semble de prime abord assez miraculeuse, puisqu'elle permet "d'effacer" la présence du paramètre de la variance asymptotique simplement en passant par un calcul de primitive. Malheureusement elle est rarement applicable dès que la dimension augmente... On s'en sort de façon plus systématique en normalisant non par l'écart-type (inconnu) mais par un estimateur consistant et en utilsant Slutsky (cf exercice 12).*

MACS 203b - Exercice 19 : Correction

Pascal Bianchi
Bruno Costacèque

1er février 2023

1 Exercices

Exercise 1. Régression logistique

Soit $\theta \in \mathbb{R}^p$ un paramètre vectoriel à estimer. On considère une suite $Y_1, \ldots, Y_n$ de variables de Bernoulli indépendantes de paramètres respectifs $p_1(\theta), \ldots, p_n(\theta)$ donnés par

$$p_i(\theta) = \sigma(\theta^\top \mathbf{x}_i) = \sigma(\langle \theta, \mathbf{x}_i \rangle),$$

où $\sigma(t) = (1 + e^{-t})^{-1}$ et où $\mathbf{x}_1, \ldots, \mathbf{x}_n$ est une suite de vecteurs déterministes de taille p. On suppose que la matrice $[\mathbf{x}_1, \ldots, \mathbf{x}_n]$ est de rang p. On désigne la fonction de log-vraisemblance par :

$$L_n(\theta) = \log p_\theta(Y_1, \ldots, Y_n),$$

avec p_θ la distribution jointe des Y_i, évaluée en $(Y_1, \ldots, Y_n)$. On supposera toujours que le supremum de L_n est atteint. On note respectivement $\nabla L_n(\theta)$ et $\nabla^2 L_n(\theta)$ le gradient et la matrice hessienne de L_n au point θ.

1. Donner l'allure de la fonction σ.
2. Écrire $L_n(\theta)$ en fonction de θ et des observations $(\mathbf{x}_i, Y_i)_{i=1\ldots n}$.
3. Montrer que $\nabla L_n(\theta) = \sum_{i=1}^n (Y_i - p_i(\theta))\mathbf{x}_i$.
4. Montrer que $\nabla^2 L_n(\theta) = -\sum_{i=1}^n p_i(\theta)(1-p_i(\theta))\mathbf{x}_i\mathbf{x}_i^\top$. Montrer que $-\nabla^2 L_n(\theta)$ est définie positive.
5. En déduire que l'estimée $\hat{\theta}_n$ au sens du maximum de vraisemblance peut être définie comme la solution d'un système d'équations que l'on précisera.

On souhaite établir la normalité asymptotique de $\sqrt{n}(\hat{\theta}_n - \theta)$ sous $\mathbb{P}_\theta$. On fait les hypothèses suivantes :

- Pour tout θ, $Q_\theta := \lim_{n\to\infty} \frac{1}{n} \sum_{i=1}^n p_i(\theta)(1 - p_i(\theta))\mathbf{x}_i\mathbf{x}_i^\top$ existe et est inversible.
- $\sup_n \frac{1}{n} \sum_{i=1}^n \|\mathbf{x}_i\|^3 < \infty$.

6. Soit pour tout k, $\ell_{n,k}(\theta) = \frac{\partial}{\partial \theta_k} L_n(\theta)$. Montrer que $\nabla \ell_{n,k}(\theta) = -\sum_i h(\theta^\top \mathbf{x}_i)\mathbf{x}_i x_{i,k}$ où $h = \sigma(1-\sigma)$.
7. Vérifier que h est 1-lipschitzienne. En déduire que $\frac{\nabla^2 L_n}{n}$ est K_n-Lipschitzienne, avec K_n une constante bornée (en n) qu'on explicitera. Pour cela on admettra que la norme matricielle euclidienne de $\mathbf{x}_i\mathbf{x}_i^\top$ est :

$$\|\mathbf{x}_i\mathbf{x}_i^\top\| = \|\mathbf{x}_i\|^2.$$

On admettra la consistence faible $\hat{\theta}_n = \theta + o_P(1)$.

8. Rappeller pourquoi il existe $\tilde{\theta}_{n,k}$ telle que $\|\tilde{\theta}_{n,k} - \theta\| \leq \|\hat{\theta}_n - \theta\|$ et

$$0 = \ell_{n,k}(\theta) + \nabla \ell_{n,k}(\tilde{\theta}_{n,k})^\top (\hat{\theta}_n - \theta)\,.$$

9. Montrer que $\nabla \ell_{n,k}(\tilde{\theta}_{n,k}) = \nabla \ell_{n,k}(\theta) + o_P(n)$ et conclure que

$$\left(\frac{\nabla^2 L_n(\theta)}{n} + o_P(1)\right) \sqrt{n}(\hat{\theta}_n - \theta) = -\frac{\nabla L_n(\theta)}{\sqrt{n}}$$

10. Montrer que $-\frac{\nabla L_n(\theta)}{\sqrt{n}}$ est asymptotiquement normal.

11. Montrer que $\frac{\nabla^2 L_n(\hat{\theta}_n)}{n} \xrightarrow{P} Q_\theta$.

12. Conclure que $\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{\mathcal{L}} \mathcal{N}(0, Q_\theta^{-1})$.

13. On note $\beta_{n,k}$ le $k$ème coefficient de la diagonale de $\left(\frac{\nabla^2 L_n(\hat{\theta}_n)}{n}\right)^{-1}$. Montrer que

$$\sqrt{\frac{n}{\beta_{n,k}}}\,(\tilde{\theta}_{n,k} - \theta_k) \xrightarrow{\mathcal{L}} \mathcal{N}(0,1)\,.$$

14. En déduire un intervalle de confiance asymptotique à $100(1-\alpha)\%$ pour θ_k.

2 Solutions

Exercise 1 1. Un script python renvoie la figure suivante pour le graphe de σ sur l'intervalle $[-5, 5]$. On observe la convergence très rapide de σ vers 0 en $-\infty$ et vers 1 en $+\infty$. En particulier σ est une fonction de répartition (c'est celle de la *loi logistique*).

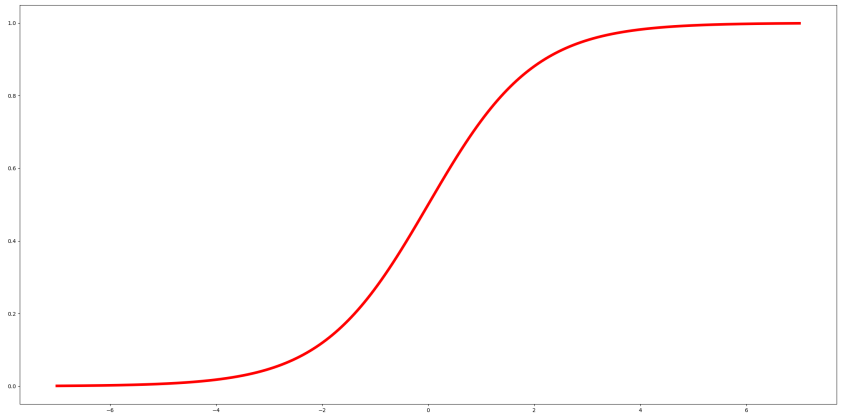


FIGURE 1 – Graphe de $\sigma : t \mapsto \frac{1}{1+e^{-t}}$

2. Par indépendance des observations, la log-vraisemblance des données s'écrit :

$$\begin{aligned}
L_n(\theta) &= \sum_{i=1}^{n} \log\left(p_i(\theta)^{Y_i}(1-p_i(\theta))^{1-Y_i}\right) \\
&= \sum_{i=1}^{n} \Big[Y_i \log p_i(\theta) + (1-Y_i)\log\big(1-p_i(\theta)\big)\Big] \\
&= -\sum_{i=1}^{n} Y_i \log\left(1+e^{-\langle\theta,\mathbf{x}_i\rangle}\right) + \sum_{i=1}^{n}\Big[(1-Y_i)\log\left(e^{-\langle\theta,\mathbf{x}_i\rangle}\right) - (1-Y_i)\log\left(1+e^{-\langle\theta,\mathbf{x}_i\rangle}\right)\Big] \\
&= -\sum_{i=1}^{n}(1-Y_i)\langle\theta,\mathbf{x}_i\rangle - \log\left(1+e^{-\langle\theta,\mathbf{x}_i\rangle}\right) \\
&= \sum_{i=1}^{n} Y_i\langle\theta,\mathbf{x}_i\rangle - \log\left(e^{\langle\theta,\mathbf{x}_i\rangle}+1\right) \\
&= \sum_{i=1}^{n} Y_i\langle\theta,\mathbf{x}_i\rangle + \log\big(1-p_i(\theta)\big),
\end{aligned}$$

vu que $-\log\left(e^{\langle\theta,\mathbf{x}_i\rangle}+1\right) = \log\big(1-p_i(\theta)\big)$, grâce à l'identité bien connue (?) :

$$1-\sigma(t) = \frac{e^{-t}}{1+e^{-t}} = \frac{1}{e^{t}+1} = \sigma(-t).$$

3. Bien que le calcul de gradient soit une opération pour le moins casse-gu**le, vous ne devriez pas avoir de problème à ce point-là de l'année à faire ce type de question. On calcule les dérivées partielles de la log-vraisemblance, en remarquant que :

$$\partial_j \log\big(1-p_i(\theta)\big) = -\partial_i \log\big(e^{\langle\theta,\mathbf{x}_i\rangle}+1\big) = -\frac{x_{i,j}}{1+e^{-\langle\theta,\mathbf{x}_i\rangle}} = -x_{i,j}p_i(\theta),$$

où $x_{i,j}$ est la j-ème variable explicative associée à la i-ème de nos données $\mathbf{x}_i$ (*i.e.* le (i,j)-ème coefficent de la matrice $[\mathbf{x}_1,\dots,\mathbf{x}_n] \in \mathcal{M}_{n,p}(\mathbb{R})$).

4. Une fois de plus, la question devient nettement plus simple en utilisant les relations vérifiées par σ. Ici on a :

$$\sigma^{'}(t) = \frac{e^{-t}}{(1+e^{-t})^2} = \sigma(t)(1-\sigma(t)).$$

Sachant cela, et grâce à la question précédente, il est aisé de retouver la Hessienne demandée. Il ne faut pas oublier non plus que :

$$\nabla\big(\theta \mapsto \langle\theta,\mathbf{x}\rangle\big) = \mathbf{x}^\top.$$

Le reste est une conséquence da la règle de la chaîne. Passons à la seconde partie de la question. Une combinaison linéaire **à coefficients positifs** de matrice positives est encore positive. Il suffit donc de montrer que toutes les matrices dans la somme donnat $-\nabla^2 L_n(\theta)$ sont positives, et que leur somme est définie (positive), c'est-à-dire inversible, ou encore injective grâce au théorème du rang. Cela revient à observer que :

$$\forall i \in [\![1,n]\!],\ \forall \mathbf{y}\in\mathbb{R}^p,\ \langle \mathbf{x}_i\mathbf{x}_i^\top\mathbf{y},\mathbf{y}\rangle = \mathbf{y}^\top\mathbf{x}_i\mathbf{x}_i^\top\mathbf{y} = (\langle\mathbf{x}_i,\mathbf{y}\rangle)^2.$$

Donc $-\nabla^2 L_n(\theta)$ est positive. Supposons maintenant que $-\nabla^2 L_n(\theta)$ ne soit pas définie positive. Dans ce cas il existe un vecteur $\mathbf{y}$ tel que :

$$\langle -L_n(\theta)\mathbf{y},\mathbf{y}\rangle = \sum_{i=1}^n p_i(\theta)(1-p_i(\theta))\langle(\mathbf{x}_i,\mathbf{y}\rangle)^2 = 0,$$

et donc, par positivité des coefficients de cette somme :

$$\forall i \in [\![1,n]\!], \langle\mathbf{x}_i,\mathbf{y}\rangle = 0.$$

C'est-à-dire que $\mathbf{y} \in \big(\mathrm{Vect}(\mathbf{x}_1,\dots,\mathbf{x}_n)\big)^\top$. Mais on sait que les $\mathbf{x}_i$ forment une base de $\mathbb{R}^p$ par hypothèse. Donc $\mathbf{y} = \mathbf{0}_{\mathbb{R}^p}$.

5. La question précédente donne que L_n est strictement concave. Ses maxima locaux sont donc globaux, et en fait elle en a au plus 1. Pour maximer L_n il suffit donc de calculer ses points critiques, c'est-à-dire de résoudre en θ le système d'équations :

$$\nabla L_n(\theta) = \sum_{i=1}^n (Y_i - p_i(\theta))\mathbf{x}_i = \mathbf{0}_{\mathbb{R}^p}.$$

6. Il s'agit simplement de la k-ème colonne de la Hessienne calculée à la question 4 !

7. On donne deux méthodes, une lourde mais qui ne requiert pas de connaissance particulière sur σ, et une autre plus astucieuse trouvée par l'un d'entre vous.

   - Puisque $\sigma^{'}(t) = \sigma(t)(1-\sigma(t)) = h(t)$, on peut calculer la dérivée seconde de σ pour en obtenir h', puis prouver que cette fonction est bornée par 1 afin d'en déduire que h est 1-lipschitzienne. On a :

$$\forall t\in\mathbb{R},\ h^{'}(t) = \frac{-e^{-t}(1+e^{-t})^2 + 2e^{-2t}(1+e^{-t})}{(1+e^{-t})^4} = \frac{e^{-3t}-e^{-t}}{(1+e^{-t})^4}.$$

   En posant $X = e^{-t} > 0$, on remarque que cette function s'écrit encore :

$$h^{'}(t) = \frac{X(X^2-1)}{(X+1)^4} = \frac{X(X-1)}{(X+1)^3} = \frac{X}{(X+1)^2}\frac{X-1}{X+1},$$

c'est-à-dire comme produit de deux fonctions bornées par 1 sur $\mathbb{R}^*$. Donc on a bien que $\forall t \in \mathbb{R},\ |h^{'}(t)| \leq 1$. On conclut par l'inégalité des accroissements finis.

- On peut aussi utliser que :

$$\begin{aligned} h^{'}(t) = \big(\sigma(t)(1-\sigma(t)\big) &= \sigma^{'}(t)(1-\sigma(t)) - \sigma(t)\sigma^{'}(t) \\ &= \sigma^{'}(t)(1-2\sigma(t)) \in]-1,1[\end{aligned}$$

car $\sigma^{'}(t) = \sigma(t)(1-\sigma(t))$ et $\sigma(t) \in]0,1[$ quelque soit $t \in \mathbb{R}$. Comme précédemment on applique l'inégalité des accroissements finis.

On en déduit que $\nabla^2 L_n$ est lipschitzienne (attention, il y a deux normes dans les inégalités suivantes : la norme euclidienne sur $\mathbb{R}^p$, et la norme matricielle associée sur $\mathcal{M}_p(\mathbb{R})$) :

$$\begin{aligned} \forall \theta, \theta^{'} \in \mathbb{R}^p,\ \|\nabla^2 L_n(\theta) - \nabla^2 L_n(\theta^{'})\| &\leq \sum_{i=1}^{n} \big|h(\theta^\top \mathbf{x}_i) - h(\theta^{'\top}\mathbf{x}_i)\big| \|\mathbf{x}_i \mathbf{x}_i^\top\| \\ &\leq \sum_{i=1}^{n} \big|\theta^\top \mathbf{x}_i - \theta^{'\top}\mathbf{x}_i\big| \|\mathbf{x}_i\|^2 \\ &\leq \sum_{i=1}^{n} \big\|\theta - \theta^{'}\big\| \|\mathbf{x}_i\| \|\mathbf{x}_i\|^2 \\ &= \big\|\theta - \theta^{'}\big\| \sum_{i=1}^{n} \|\mathbf{x}_i\|^3 \end{aligned}$$

En posant $K_n = \frac{1}{n}\sum_{i=1}^{n} \|\mathbf{x}_i\|^3$, et en utilisant l'hypothèse de l'énoncé, on retrouve bien que K_n est bornée par rapport à n, et donc le résutat attendu.

8. Pour commencer, remarquons que :

$$\ell_{n,k}(\hat{\theta}_n) = \partial_k L_n(\hat{\theta}_n) = 0,$$

puisque $\hat{\theta}_n$ est un zéro du gradient de L_n (*i.e.* un point critique de L_n), donc annule toutes ses fonctions coordonnées $\ell_{n,k}$. De plus on reconnaît dans l'énoncé un resultat de type "égalité des accroissements finis" (EAF). Plus précisément, on applique l'EAF à la fonction d'une variable réelle g définie sur $[0,1]$ par :

$$g : t \mapsto \ell_{n,k}(\theta + t\big(\hat{\theta}_n - \theta\big)\big).$$

Puisque $g(1) = \ell_{n,k}(\hat{\theta}_n) = 0$ et $g(0) = \ell_{n,k}(\theta)$, l'EAF donne qu'il existe $s \in]0,1[$ tel que :

$$0 = g(1) = g(0) + \nabla g'(s)(1-0) = \ell_{n,k}(\theta) + \nabla \ell_{n,k}\big(\theta + s\big(\hat{\theta}_n - \theta\big)\big)^\top (\hat{\theta}_n - \theta).$$

En posant $\tilde{\theta}_{n,k} = \theta + s\big(\hat{\theta}_n - \theta\big)$, on retrouve bien les deux conditions attendues.

9. Le but de cette question est de se débarrasser de $\tilde{\theta}_{n,k}$ (dont on ne sait pas grand chose) en comparant $\nabla \ell_{n,k}(\tilde{\theta}_{n,k})$ à $\nabla \ell_{n,k}(\theta)$. Pour cela on va montrer que $\nabla \ell_{n,k}(\tilde{\theta}_{n,k}) - \nabla \ell_{n,k}(\theta)$ est petit par rapport à n :

$$\begin{aligned}
\|\nabla \ell_{n,k}(\tilde{\theta}_{n,k}) - \nabla \ell_{n,k}(\theta)\| &\leq \sum_{i=1}^{n} \big|h(\tilde{\theta}_{n,k}^\top \mathbf{x}_i) - h(\theta^\top \mathbf{x}_i)\big| |x_{i,k}| \|\mathbf{x}_i\| \\
&\leq \sum_{i=1}^{n} |\tilde{\theta}_{n,k}^\top \mathbf{x}_i - \theta^\top \mathbf{x}_i| |x_{i,k}| \|\mathbf{x}_i\| \\
&\leq \sum_{i=1}^{n} \big\|\tilde{\theta}_{n,k} - \theta\big\| |x_{i,k}| \|\mathbf{x}_i\|^2 \\
&\leq \big\|\tilde{\theta}_{n,k} - \theta\big\| \sum_{i=1}^{n} \|\mathbf{x}_i\|^3 \\
&= o_P(1) O_P(n) \\
&= o_P(n).
\end{aligned}$$

On a utilisé successivement les arguments suivants : h est 1-lipschitzienne, l'inégalité de Cauchy-Schwartz, $|x_{i,k}| \leq \|\mathbf{x}_i\|$, ainsi que les hypothèses de l'énoncé sur $\sum_{i=1}^n \|\mathbf{x}_i\|^3$ et la consistence faible de $\hat{\theta}_n$.
Par conséquent, en réinjectant ce résultat dans l'égalité de la question 8, on trouve le développement limité :

$$0 = \ell_{n,k}(\theta) + \nabla \ell_{n,k}(\theta)^\top (\hat{\theta}_n - \theta) + o_P(n)(\hat{\theta}_n - \theta).$$

On reconnaît un développement limité des p lignes du gradient de L_n au voisinage de θ (par définition de $\ell_{n,k}$). En les rassemblant, on en déduit le développement limité suivant du gradient de L_n entre θ et $\hat{\theta}_n$:

$$\mathbf{0}_{\mathbb{R}^p} = \nabla L_n(\theta) + \nabla^2 L_n(\theta)^\top (\theta_n - \theta) + o_P(n)(\hat{\theta}_n - \theta).$$

En divisant par $\sqrt{n}$ des deux côtés, on trouve finalement :

$$\begin{aligned}
\mathbf{0}_{\mathbb{R}^p} &= \frac{1}{\sqrt{n}} \nabla L_n(\theta) + \frac{1}{\sqrt{n}} \nabla^2 L_n(\theta)^\top (\theta_n - \theta) + o_P(\sqrt{n})(\hat{\theta}_n - \theta) \\
&= \frac{1}{\sqrt{n}} \nabla L_n(\theta) + \Big(\frac{1}{n} \nabla^2 L_n(\theta) + o_P(1)\Big)^\top \sqrt{n}(\theta_n - \theta).
\end{aligned}$$

10. Par la question 3, en posant $\mathbf{Z}_{n,i} := (Y_i - p_i(\theta))\mathbf{x}_i/\sqrt{n}$, on a que

$$\frac{\nabla L_n(\theta)}{\sqrt{n}} = \sum_{i=1}^{n} \frac{(Y_i - p_i(\theta))}{\sqrt{n}} \mathbf{x}_i = \sum_{i=1}^{n} \mathbf{Z}_{n,i}.$$

On n'est pas dans les conditions d'application du théorème central limite usuel (les $Z_{n,i}$ ne sont pas identiquement distribuées). On va donc utliser le théorème 2.22 de votre cours (celui qui est dégeu, avec la condition horrible de Lindebergh à vérifier...). Les vecteurs aléatoires $Z_{n,i}$ sont clairement indépendants et centrés (on rappelle que les $\mathbf{x}_i$ sont des vecteurs déterministes eux !). De plus la matrice de covariance de $\mathbf{Z}_{n,i}$ est :

$$\Sigma_{\mathbf{Z}_{n,i}} = \frac{1}{n} p_i(\theta)\big(1 - p_i(\theta)\big)\mathbf{x}_i \mathbf{x}_i^\top.$$

Grâce aux hypothèses de l'énoncé, on a donc précisément que $\sum_{i=1}^n \Sigma_{\mathbf{Z}_{n,i}}$ converge vers une matrice notée Q_θ. Par l'hypothèse définissant Q_θ, on sait aussi que :

$$\frac{\nabla^2 L_n(\theta)}{n} \xrightarrow{P} Q_\theta.$$

Reste à vérifier la condition de Lindebergh. On a :

$$\begin{aligned}
\forall \varepsilon > 0,\ \sum_{i=1}^n \mathbb{E}\Big[\|\mathbf{Z}_{n,i}\|^2 \mathbb{1}_{\{\|\mathbf{Z}_{n,i}\| \geq \varepsilon\}}\Big] &= \frac{1}{n}\sum_{i=1}^n \mathbb{E}\Big[\big(Y_i - p_i(\theta)\big)^2 \|\mathbf{x}_i\|^2 \mathbb{1}_{\left\{\left(Y_i - p_i(\theta)\right)\|\mathbf{x}_i\| \geq \sqrt{n}\varepsilon\right\}}\Big] \\
&= \frac{1}{n}\sum_{i=1}^n \|\mathbf{x}_i\|^2 \mathbb{E}\Big[\big(Y_i - p_i(\theta)\big)^2 \mathbb{1}_{\left\{\left(Y_i - p_i(\theta)\right)\|\mathbf{x}_i\| \geq \sqrt{n}\varepsilon\right\}}\Big] \\
&\leq \frac{1}{n}\sum_{i=1}^n \|\mathbf{x}_i\|^2 \mathbb{E}\Big[\mathbb{1}_{\left\{\left(Y_i - p_i(\theta)\right)\|\mathbf{x}_i\| \geq \sqrt{n}\varepsilon\right\}}\Big] \\
&= \frac{1}{n}\sum_{i=1}^n \|\mathbf{x}_i\|^2 \mathbb{P}\Big(\big(Y_i - p_i(\theta)\big)\|\mathbf{x}_i\| \geq \sqrt{n}\varepsilon\Big) \\
&\leq \frac{1}{\varepsilon n\sqrt{n}}\sum_{i=1}^n \|\mathbf{x}_i\|^3 \mathbb{E}\big[|Y_i - p_i|\big] \\
&\leq \frac{1}{\varepsilon\sqrt{n}} \sup_{n\geq 1} \frac{1}{n}\sum_{i=1}^n \|\mathbf{x}_i\|^3.
\end{aligned}$$

Ce dernier supremum est fini grâce aux hypothèses de l'énoncé. On a utlisé à deux reprises que $|Y_i - p_i(\theta)| \leq 1$, car Y_i et $p_i(\theta)$ sont des réels positifs majorés par 1 et une fois l'inégalité de Markov pour la variable positive $|Y_i - p_i(\theta)|$.

11. Pour remplacer θ par $\hat{\theta}_n$ dans cette limite, on utilise que $\frac{\nabla^2 L_n}{n}$ est K-lipschitzienne, avec $K := \sup_n K_n < \infty$ grâce à la question 7 :

$$\begin{aligned}
\Big\|\frac{\nabla^2 L_n(\hat{\theta}_n)}{n} - Q_\theta\Big\| &\leq \frac{1}{n}\Big\|\nabla^2 L_n(\hat{\theta}_n) - \nabla^2 L_n(\theta)\Big\| + \Big\|\frac{\nabla^2 L_n(\theta)}{n} - Q_\theta\Big\| \\
&\leq K\|\hat{\theta}_n - \theta\| + \Big\|\frac{\nabla^2 L_n(\theta)}{n} - Q_\theta\Big\|.
\end{aligned}$$

Le second terme tend vers 0 en probabilité, le premier vers 0 aussi par consistance faible des M-estimateurs. Ainsi la somme tend vers 0 en probabilité, ce qui conclut.

12. L'ensemble $\mathcal{G}_p(\mathbb{R})$ des matrices inversibles de $\mathbb{R}^p$ est ouvert. Comme $Q_\theta \in \mathcal{G}_p(\mathbb{R})$, cela signifie que pour n assez grand, la matrice

$$A_n := \frac{\nabla^2 L_n}{n}$$

est inversible, puisque sa limite (en probabilité) est Q_θ. Cela reste vrai en perturbant encore A_n avec un $o_P(1)$. Donc le développement limité de la question 9 se réecrit :

$$\sqrt{n}(\hat{\theta}_n - \theta) = -\left(\frac{\nabla^2 L_n(\theta)}{n} + o_P(1)\right)^{-1} \frac{\nabla L_n(\theta)}{\sqrt{n}}.$$

Par continuité de l'inverse matriciel, on a grâce à la question que

$$\left(\frac{\nabla^2 L_n(\theta)}{n} + o_P(1)\right)^{-1} \xrightarrow{P} Q_\theta^{-1}.$$

Le lemme de Slutsky et la question 10 permettent de conclure.

13. Il suffit d'observer que :

$$\sqrt{n}(\tilde{\theta}_{n,k} - \theta_k) = \big\langle \sqrt{n}(\tilde{\theta}_n - \theta), \mathbf{e}_k \big\rangle,$$

avec $\mathbf{e}_k$ le k-ème élément de la base canonique. Par continuité de l'application $\mathbf{x} \mapsto \langle \mathbf{x}, \mathbf{e}_k \rangle$, on a :

$$\sqrt{n}(\tilde{\theta}_{n,k} - \theta_k) = \big\langle \sqrt{n}(\tilde{\theta}_n - \theta), \mathbf{e}_k \big\rangle \underset{n\to\infty}{\Longrightarrow} \big\langle \mathcal{N}(0, Q_\theta^{-1}), \mathbf{e}_k \big\rangle = \mathcal{N}(0, \beta_k),$$

avec β_k le k-ème coefficient de Q_θ^{-1}. En renormalisant par la racine de la variance de ce produit scalaire (son écart-type donc), à savoir $\beta_{n,k}$, on retrouve le résultat attendu grâce à Slutsky : on sait par la question 12 que

$$\frac{\nabla^2 L_n(\hat{\theta}_n)}{n} \xrightarrow{P} Q_\theta,$$

donc en particulier $\beta_{n,k} \xrightarrow{P} \beta_k$.

14. La technique est la même que d'habitude : on prend un réel q quelconque, qu'on fixera plus tard, et on utilise l'approximation :

$$\mathbb{P}\Big(\sqrt{\frac{n}{\beta_{n,k}}}\,|\tilde{\theta}_{n,k} - \theta_k| \le q\Big) \simeq \mathbb{P}\big(|Z| \le q\big) = 2\Phi(x) - 1,$$

où Φ est la fonction de répartition de Z, une variable aléatoire suivant la loi normale $\mathcal{N}(0,1)$. Observons que les coefficients $\beta_{n,k}$ sont strictements positifs : ce sont les coefficients diagonaux d'une matrice symétrique définie positive (l'inverse d'une matrice définie positive l'est encore), et si S est une telle matrice, son i-ème coefficient diagonal vérifie :

$$s_{i,i} = \langle S\mathbf{e}_i, \mathbf{e}_i \rangle > 0,$$

Comme déjà vu dans les précédents TD, on trouve :

$$\mathbb{P}\Big(\sqrt{\frac{n}{\beta_{n,k}}}\,|\tilde{\theta}_{n,k} - \theta_k| \le q\Big) = \mathbb{P}\Big(\tilde{\theta}_{n,k} - q\sqrt{\frac{\beta_{n,k}}{n}} \le \theta_k \le \tilde{\theta}_{n,k} + q\sqrt{\frac{\beta_{n,k}}{n}}\Big),$$

et en choisissant q tel que $2\Phi(q) - 1 = 1 - \alpha$, *i.e.* en prenant [1] $q = q_{1-\alpha}$ le quantile au niveau $1-\alpha$ de la loi normale $\mathcal{N}(0,1)$, on trouve comme intervalle de confiance asymptotique au niveau désiré :

$$\mathcal{J}_{n,\alpha} := \Big[\tilde{\theta}_{n,k} - q_{1-\alpha}\sqrt{\frac{\beta_{n,k}}{n}}, \tilde{\theta}_{n,k} + q_{1-\alpha}\sqrt{\frac{\beta_{n,k}}{n}}\Big].$$

1. Attention au sens qu'on donne à α : ici il s'agit du risque qu'on sorte de l'intervalle de confiance, donc on prend α petit ($= 0.05$ par exemple).