MDI220

TD 6

Tests d'hypothèses et Intervalle de confiance

Exercice 1 : Test de Neyman-Pearson pour gaussiennes à moyenne connue.

1. Soit Y un vecteur gaussien centré de taille n. On veut tester l'hypothèse $H_0 : Y \sim \mathcal{N}(0, \Sigma_0)$ versus $H_1 : Y \sim \mathcal{N}(0, \Sigma_1)$ où Σ_0, Σ_1 sont inversibles. Montrer que le test de Neyman-Pearson revient à comparer $y^T(\Sigma_1^{-1} - \Sigma_0^{-1})y$ à un seuil.
2. Soient X et W deux variables gaussiennes scalaires réelles, centrées, de variances respectives σ_X^2 et σ_V^2. La variable X est un signal utile et W est un bruit de mesure. L'observation est donnée par $Y = X + W$. On reçoit n observations indépendantes.

   Proposer un test au niveau α permettant de détecter la présence du signal X.
3. Pour le test précédent, donner la valeur du seuil en fonction des quantiles de la loi du chi-deux. On précise que la loi du chi-deux à n degrés de libertés est la loi suivie par la somme des carrés de n variables normales centrées réduites indépendantes :

$$X \sim \chi_n^2 \iff X \overset{\text{loi}}{=} \sum_1^n U_i^2 \text{ où } U_i \overset{i.i.d.}{\sim} \mathcal{N}(0,1)\,.$$

Exercice 2 : Test pour une certification bio. Pour avoir la certification "bio", un fabricant de produits "bios" doit garantir pour chaque lot un pourcentage d'OGM inférieur à 1%. Il prélève donc $n = 25$ produits par lot et teste si le pourcentage d'OGM est inférieur à 1%. On note X_i le logarithme en base 10 du pourcentage d'OGM du paquet numéro i.

Modèle : On suppose que les X_i sont indépendants et suivent une loi gaussienne $\mathcal{N}(\theta, 1)$.

1. Pour $\theta_1 > \theta_0$, montrer que le test de Neyman-Pearson de niveau α de $H_0 : \theta = \theta_0$ contre $H_1 : \theta = \theta_1$ est de la forme $\bar{X}_n > t_{n,\alpha}$.
2. Pour le fabriquant, le pourcentage d'OGM est inférieur à 1% sauf preuve du contraire. Il veut tester l'hypothèse $H_0 : \theta \leq 0$ contre $H_1 : \theta > 0$ et il souhaite que pour $\theta \leq 0$ le test se trompe avec une probabilité inférieure à 5%. Calculer un seuil $t_{25,5}$ tel que

$$\sup_{\theta \leq 0} \mathbb{P}_\theta(\bar{X}_{25} > t_{25,5}) = 5\%.$$

   On pourra utiliser que $\mathbb{P}(Z > 1.645) \approx 5\%$, pour $Z \sim \mathcal{N}(0,1)$.
3. Une association "anti-OGM" veut s'assurer qu'il n'y a effectivement pas plus de 1% d'OGM dans les produits labélisés "bio". En particulier, elle s'inquiète de savoir si le test parvient à éliminer les produits pour lesquels le pourcentage d'OGM dépasse de 50% le maximum autorisé. Quelle est la probabilité que le test ne rejette pas H_0 lorsque le pourcentage d'OGM est de 1.5% ?
4. Scandalisée par le résultat précédent, l'association milite pour que le test du fabricant prouve effectivement que le pourcentage d'OGM est inférieur à 1%. Pour elle, le pourcentage d'OGM est supérieur à 1% sauf preuve du contraire, donc H_0 est $\theta > 0$ et H_1 est $\theta \leq 0$. Proposer un test de H_0 contre H_1 tel que la probabilité que le test rejette à tort H_0 soit inférieure à 5%.

Exercice 3 : Loi uniforme. Soit $(X_i)_{i=1,\dots n}$ des variables aléatoire i.i.d. selon une loi uniforme sur $[0, \theta]$ ($\theta > 0$), et $X = (X_1, \dots X_n)$.

1. On pose $M_n(X) = \max_{i=1}^n X_i$. Donner la loi de M_n.

2. En déduire une fonction pivotale $\varphi(M_n(X), \theta)$ telle que la loi de $Z = \varphi(M_n(X), \theta)$ ne dépende pas de θ. On va supposer que pour une variable aléatoire X de fonction de répartition F continue sur $\mathbb{R}$, la variable aléatoire $U = F(X)$ suit une loi uniforme sur $[0, 1]$.
3. En déduire un intervalle de confiance pour le paramètre θ de type $I = [M_n(X), R(X)]$ de niveau de confiance $1 - \alpha$.
4. Pour $\theta_0 > 0$, on considère le test d'hypothèse : $H_0 : \theta \geq \theta_0$. En utilisant la dualité tests-intervalles de confiance, et en étudiant le sens de variation de la fonction $\theta \mapsto \mathbb{P}_\theta(M_n(X) < c)$ (c fixé), construire un test de l'hypothèse H_0 (contre $H_1 = H_0^c$) de niveau α.
5. Application numérique : $n = 10$, et $M_n(X) = 5$. Quel intervalle de confiance de niveau 95% obtenez-vous ? Rejetez-vous l'hypothèse $H_0 : \theta \geq 6$?

Exercice 4 : Maximum de vraisemblance et test de Fisher pour le modèle linéaire. Pour tout $i = 1 \cdots n$, on considère

$$Y_i = x_{i,1}\theta_1 + \cdots + x_{i,p}\theta_p + V_i \tag{1}$$

où $V_i \sim \mathcal{N}(0, \sigma^2)$. Les coefficients $x_{i,1}, \cdots, x_{i,p}$ sont des variables déterministes connues. Les paramètres θ et σ^2 sont inconnus. On observe $Y_1, \cdots, Y_n$ supposées indépendantes, avec $n \geq p$.

1. Montrer que le vecteur Y s'écrit
$$Y = M\theta + V$$
où $\theta = (\theta_0, \cdots, \theta_p)^T$ et M est une matrice que l'on exprimera. On suppose dorénavant que M est de rang plein (c'est-à-dire, de $\mathrm{rang}(M) = p$).
2. Exprimer l'estimateur $(\widehat{\theta}, \widehat{\sigma}^2)$ de (θ, σ^2) du maximum de vraisemblance. Montrer que $\widehat{\theta}$ coïncide avec l'estimateur des moindres carrés.
3. Montrer que $\widehat{\theta}$ est non biaisé.
4. Soit V un sous-espace vectoriel de $\mathbb{R}^n$ de dimension $k \leq n$. Soit Π_V le projecteur orthogonal sur V. Soit $X \sim \mathcal{N}(0, I_n)$. Calculer $\mathbb{E}(\|\Pi_V X\|^2)$.
5. En déduire que $\widehat{\sigma}^2$ est un estimateur biaisé et calculer son biais.
6. Proposer un estimateur non biaisé de σ^2.
7. On s'intéresse aux hypothèses :
$$\begin{array}{ll} H_0 : & \theta_1 = \cdots = \theta_p = 0 \\ H_1 : & \exists j \in \{1 \cdots p\},\ \theta_j \neq 0\,. \end{array}$$
Fournir un test de niveau α donné en utilisant un critère basé sur la statistique du rapport de vraisemblance « généralisé », c'est-à-dire sur la statistique
$$Z(Y) = \frac{\sup_{\theta \in \Theta} p_\theta(Y)}{\sup_{\theta \in \Theta_0} p_\theta(Y)},$$
où $y \mapsto p_\theta(y)$ est la densité de la variable aléatoire Y définie par (1).